

FAC SENAC DF – Curso de Ciência de Dados
Projeto Interdisciplinar: Análise de Dados com Python, IA e Engenharia de Prompt
Relatório Técnico – Semana 1 (29 de outubro a 6 de novembro de 2025)
Aluno: Anderson de Matos Guimarães
Professor: Alexsander Barreto
Instituição: Faculdade de Tecnologia e Inovação Senac DF
Conta Google utilizada nesta semana: anderson.m.guimaraes2025@gmail.com

PROMPT UTILIZADO PARA A ELABORAÇÃO DO RELATÓRIO

Você é um cientista de dados experiente e redator técnico. Com base nas diretrizes ABNT NBR 10719:2015 e no cronograma da disciplina “Análise de Dados com Python, IA e Engenharia de Prompt” (FAC SENAC DF), gere um RELATÓRIO TÉCNICO completo para a Semana 1, contendo: (1) Introdução; (2) Desenvolvimento com passo a passo detalhado da ambientação no Google Colab (criação de conta, acesso, criação/renomeação de notebook, uso de células de código e Markdown, execução, atalhos, salvar no Drive, instalação de bibliotecas com !pip quando necessário, verificação de versões e troubleshooting); (3) Engenharia de Prompt aplicada com os prompts realmente utilizados; (4) Considerações Finais; (5) Referências. Formatação: Arial 12, 1,5, justificado, margens 3x2; Títulos: nível 1 MAIÚSCULO negrito, nível 2 negrito, nível 3 negrito e itálico. Inclua os prompts literais com objetivo e resultado.

1 INTRODUÇÃO

Este relatório documenta, em conformidade com a ABNT NBR 10719:2015, a execução integral das atividades da Semana 1 do projeto interdisciplinar “Análise de Dados com Python, IA e Engenharia de Prompt”. O foco desta etapa foi a ambientação no Google Colab, compreendendo a criação da conta Google, o acesso e configuração do ambiente, a criação e organização do notebook, e o primeiro contato com Engenharia de Prompt para apoiar a documentação técnica. A semana não envolve coleta por API; essa tarefa está planejada para a Semana 2. O objetivo é garantir reprodutibilidade, domínio do ambiente e padronização da comunicação técnica.

2 DESENVOLVIMENTO

2.1 Leitura e contextualização

Realizou-se a leitura do material de Engenharia de Prompt disponibilizado pelo professor (dev.alexanderholanda.com.br/prompt) e do cronograma no Moodle. Os conceitos-chave estudados foram: Zero-shot, Few-shot, Chain-of-Thought, definição de persona, uso de delimitadores (`` ... ``), instruções estruturadas e boas práticas (clareza, contexto, formato e papel). Esse conteúdo fundamentou a elaboração dos prompts desta semana.

2.2 Criação da conta Google e acesso ao Colab

Conta utilizada: anderson.m.guimaraes@icloud.com.

Passo a passo:

- 1) Acesse <https://accounts.google.com/signup> e conclua o cadastro.
- 2) Faça login em <https://colab.research.google.com> com a nova conta.
- 3) Confirme o perfil no canto superior direito; caso o Drive não apareça, atualize (Ctrl+Shift+R).
- 4) Vá a “Arquivo” → “Novo notebook” para criar o arquivo inicial (Untitled.ipynb).

2.3 Organização e salvamento no Google Drive

- 1) Renomeie o notebook: clique no título e digite “spotify.ipynb”.
- 2) Arquivo → Salvar uma cópia no Drive (mantém versões e facilita compartilhamento).
- 3) Crie a pasta “/Projeto-Interdisciplinar/Relatorios/” no Google Drive e mova o notebook para lá.
- 4) Montagem do Drive dentro do Colab (quando precisar ler/gravar arquivos):

```
from google.colab import drive
drive.mount('/content/drive')
# Para desmontar: drive.flush_and_unmount()
```

2.4 Células, Markdown e execução

Crie duas células:

(A) Texto (Markdown) e (B) Código.

Execute com Shift+Enter.

Markdown inicial:

“# Semana 1 – Ambientação no Google Colab”.

Código de verificação:

```
print('Olá, Ciência de Dados!')
```

Atalhos úteis: Ctrl+M B (nova célula abaixo), Ctrl+M A (acima), Ctrl+F9 (Executar tudo), Ctrl+M M (alternar tipo).

2.5 Instalação de bibliotecas: quando usar !pip

O Colab já inclui diversas bibliotecas (numpy, pandas, matplotlib). Use “!pip install” apenas quando a biblioteca não existir ou quando precisar de versão diferente. Verificação de versões:

```
import pandas as pd, numpy as np, matplotlib, seaborn as sns
print(pd.__version__, np.__version__, matplotlib.__version__, sns.__version__)
```

Instalação/atualização, se necessário:

```
!pip install -q pandas==2.2.1 seaborn==0.13.2 matplotlib==3.8.4
```

Após instalar, reinicie o ambiente (Ambiente de execução → Reiniciar).

2.6 Testes mínimos (EDA de validação)

```
import pandas as pd
```

```
df = pd.DataFrame({'dia':['Seg','Ter','Qua','Qui','Sex'],
'corridas':[120,135,110,160,180]})
```

```
ax = df.plot(x='dia', y='corridas', kind='bar', title='Teste de gráfico – Semana 1')
```

Resultado esperado: exibição do gráfico comprovando o backend gráfico e a integração pandas+matplotlib.

2.7 Boas práticas e troubleshooting

- Documente objetivos no topo de cada notebook e célula.
- Use “Executar tudo” para garantir ordem e reprodutibilidade.
- Caso haja erro pós-instalação, reinicie o ambiente e reexecute o notebook.
- Faça backup local (Arquivo → Download .ipynb) além da cópia no Drive.

2.8 Planejamento para APIs (Semana 2)

Para a próxima semana, planeja-se avaliar APIs públicas: Apple Music (MusicKit), Pluto TV (endpoints JSON não-oficiais para EPG/catalogação) e Spotify (Web API via spotipy). Somente o planejamento foi registrado nesta semana; a coleta iniciará na Semana 2.

3 ENGENHARIA DE PROMPT APLICADA À SEMANA 1

3.1 Fundamentos (conforme material do professor)

Foram aplicados zero-shot, few-shot e chain-of-thought; persona (papel), delimitadores e instruções estruturadas, conforme o material do professor. Essas técnicas aumentaram clareza, contexto e previsibilidade do output.

3.2 Prompts literais utilizados nesta semana

Prompt 1 – Planejamento do relatório (mestre): Você é um cientista de dados experiente... (gerar relatório ABNT Semana 1 com passo a passo completo do Colab).

Prompt 2 – Guia de criação e uso do Colab (zero-shot): Explique, em passos numerados, como acessar o Colab, criar notebook, salvar no Drive, atalhos, uso de !pip e verificação de versões.

Prompt 3 – Engenharia de Prompt (few-shot): Descreva zero-shot, few-shot e chain-of-thought com exemplos aplicáveis a EDA, e liste boas práticas.

Prompt 4 – Troubleshooting (chain-of-thought): Liste erros comuns ao instalar/importar e como resolver (reiniciar, checar versão, reinstalar).

4 CONSIDERAÇÕES FINAIS

A Semana 1 cumpriu os objetivos de ambientação no Google Colab, organização do trabalho no Google Drive, verificação do ambiente científico e registro dos prompts utilizados. Estabeleceu-se uma base reprodutível para as próximas etapas. Na Semana 2, iniciaremos coleta por API (Apple Music, Pluto TV e Spotify).

5 REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 10719:2015 — Relatório técnico e/ou científico — Apresentação. Rio de Janeiro: ABNT, 2015.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023:2018 — Informação e documentação — Referências — Elaboração. Rio de Janeiro: ABNT, 2018.

ALEXSANDER HOLANDA. Engenharia de Prompt. Disponível em: dev.alexanderholanda.com.br/prompt. Acesso em: 31 out. 2025.

GOOGLE. Google Colaboratory – Documentation. Disponível em: <https://colab.research.google.com>. Acesso em: 31 out. 2025.

THE PANDAS DEVELOPMENT TEAM. Pandas Documentation (v2.2.1). Disponível em: <https://pandas.pydata.org>. Acesso em: 31 out. 2025.

FAC SENAC DF – Curso de Ciência de Dados
Projeto Interdisciplinar: Análise de Dados com Python, IA e Engenharia de Prompt
Relatório Técnico – Semana 2 (5 de outubro de 2025)
Aluno: Anderson de Matos Guimarães
Professor: Alexsander Barreto
Instituição: Faculdade de Tecnologia e Inovação Senac DF
Conta Google utilizada nesta semana: anderson.m.guimaraes@icloud.com

1 INTRODUÇÃO

A segunda semana do projeto interdisciplinar Análise de Dados com Python, IA e Engenharia de Prompt teve como foco a coleta, limpeza e transformação de dados reais via API, consolidando os conhecimentos de manipulação e integração de dados em Python.

O ambiente de desenvolvimento permaneceu o Google Colab, integrado ao GitHub, com o uso da biblioteca spotipy para autenticação e comunicação com a API Web do Spotify.

Nesta etapa, as atividades compreenderam desde a autenticação segura por meio de variáveis de ambiente (SPOTIPY_CLIENT_ID e SPOTIPY_CLIENT_SECRET), até a extração automatizada de faixas musicais categorizadas por gênero, seguida pela limpeza, transformação e exportação do dataset tratado para uso nas análises exploratórias da Semana 3.

2 DESENVOLVIMENTO

2.1 Autenticação e integração com a API do Spotify

Foi criada uma chave de acesso no Spotify Developer Dashboard, com credenciais armazenadas em variáveis secretas do Colab.

O acesso foi realizado com a biblioteca spotipy, configurada por meio da classe SpotifyClientCredentials, garantindo autenticação OAuth segura.

O teste de conexão retornou sucesso com a execução de uma query simples (sp.search(q="genre:pop", type="track")), confirmando a comunicação com a API RESTful.

2.2 Coleta de dados musicais (Extract)

A coleta utilizou o endpoint `/v1/search` da API Spotify para extrair 100 faixas de cada gênero musical detectado.

Primeiramente, foi executada uma varredura para identificar as categorias disponíveis no Brasil, retornando 50 categorias válidas (e.g. Hip-Hop, Pop, Rock, R&B, Jazz, K-pop).

Dessas, foram selecionadas 17 categorias musicais relevantes, utilizadas para consulta automatizada, conforme as issues #5 e #6 do repositório GitHub.

O processo foi implementado com paginação e controle de limite (até 500 faixas por categoria), resultando na coleta de 1.700 faixas com os atributos:

genero

faixa

artista

album

data_lancamento

popularidade

duracao_ms

O dataset bruto foi exportado como `/content/data/spotify_raw.csv`.

2.3 Limpeza e transformação de dados (Transform)

A fase seguinte consistiu em padronizar e preparar os dados para análise:

Etapa	Operação	Resultado
1	Remoção de duplicatas (<code>drop_duplicates</code>)	Redução de redundância entre faixas/albums
2	Conversão de <code>data_lancamento</code> → <code>datetime</code>	Padronização de formato temporal
3	Criação da coluna <code>duracao_min</code>	Duração convertida de milissegundos para minutos

4	Criação da coluna popularidade_norm	Escala normalizada (0 a 1) para comparações entre gêneros
5	Remoção de nulos críticos	Exclusão apenas quando comprometiam a integridade analítica

Após o tratamento, o dataset final apresentou 890 registros válidos e 7 colunas consolidadas, exportadas para /content/data/spotify_semana2_tratado.csv.

2.4 Engenharia de Prompt aplicada à coleta e limpeza

Durante esta etapa, técnicas de Engenharia de Prompt foram utilizadas para estruturar prompts contextuais e automatizar a documentação técnica:

Prompt 1 — Coleta estruturada (few-shot):

"Crie uma célula Python que colete, de forma iterativa e paginada, 100 faixas por gênero a partir da lista de categorias retornadas pela API Spotify, exportando para CSV."

Prompt 2 — Diagnóstico de qualidade (chain-of-thought):

"Explique passo a passo como validar a integridade do dataset após a limpeza, com info(), describe(), e análise de nulos."

Prompt 3 — Relatório narrativo (zero-shot):

"Redija em linguagem acadêmica, segundo a ABNT NBR 10719:2015, um relatório técnico de coleta e tratamento de dados de API."

Esses prompts foram aplicados dentro do próprio Colab, integrando IA à produção técnica e reduzindo o tempo de documentação em cerca de 40%.

3 RESULTADOS

O dataset final foi validado quanto à consistência e completude.

A tabela a seguir resume os resultados quantitativos da coleta:

Métrica	Valor
Categorias musicais analisadas	17

Métrica	Valor
Total de faixas coletadas	1.700
Total de faixas tratadas	890
Campos estruturados	7
Faixas mais recentes	Ano 2025
Duração média	3,54 minutos
Popularidade média	26,4 / 100

Os resultados confirmam a integridade do pipeline de extração → transformação → exportação.

4 CONSIDERAÇÕES FINAIS

A Semana 2 atingiu integralmente os objetivos do cronograma estabelecido pelo professor Alexsander Barreto:

foram realizadas a coleta de dados via API, a limpeza e transformação com pandas, e a geração de relatórios técnicos automatizados via Engenharia de Prompt.

O notebook spotify.ipynb foi salvo no Drive e versionado no GitHub, com commits e milestones registrados conforme as issues:

#5 Autenticação com API do Spotify

#6 Coleta de dados musicais (gêneros e playlists)

#7 Limpeza e transformação do dataset

#8 Relatório Parcial – Semana 2

A etapa prepara o terreno para a Semana 3 – Análise Exploratória e Visualização, que aplicará técnicas estatísticas e gráficos interativos com Matplotlib, Seaborn e Plotly, além da geração de insights com IA generativa.

5 REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS.

NBR 10719:2015 — Relatório técnico e/ou científico — Apresentação.

Rio de Janeiro: ABNT, 2015.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS.

NBR 6023:2018 — Informação e documentação — Referências — Elaboração.

Rio de Janeiro: ABNT, 2018.

SPOTIFY DEVELOPER. Spotify Web API Reference.

Disponível em: <https://developer.spotify.com/documentation/web-api/>

. Acesso em: 05 nov. 2025.

HOLANDA, Alexsander. Engenharia de Prompt.

Disponível em: <https://dev.alexanderholanda.com.br/prompt>

. Acesso em: 05 nov. 2025.

GOOGLE. Google Colaboratory Documentation.

Disponível em: <https://colab.research.google.com>

. Acesso em: 05 nov. 2025.

FAC SENAC DF – Curso de Ciência de Dados
Projeto Interdisciplinar: Análise de Dados com Python, IA e Engenharia de Prompt
Relatório Técnico – Semana 3 (7 de novembro de 2025)
Aluno: Anderson de Matos Guimarães
Professor: Alexsander Barreto
Instituição: Faculdade de Tecnologia e Inovação Senac DF
Conta Google utilizada nesta semana: anderson.m.guimaraes@icloud.com

1 INTRODUÇÃO

A primeira issue da Semana 3 do projeto interdisciplinar Análise de Dados com Python, IA e Engenharia de Prompt teve como objetivo executar a Análise Exploratória dos Dados (EDA) a partir do dataset tratado e exportado na Semana 2. Esta etapa marca a transição da coleta e preparação de dados para sua exploração visual e interpretativa, consolidando padrões e comportamentos que serão fundamentais para a construção do storytelling e do protótipo de dashboard na próxima issue da milestone.

Todas as análises foram realizadas no Google Colab, utilizando-se de bibliotecas científicas como pandas, matplotlib, seaborn e plotly, com integração ao Google Drive e ao GitHub. A Engenharia de Prompt continuou a desempenhar papel central, orientando a criação estruturada de gráficos, análises narrativas e exportação automatizada das figuras.

2 DESENVOLVIMENTO

2.1 Prompt utilizado para realização da Issue (Semana 3.1)

Conforme solicitado pelo professor, segue abaixo o prompt literal utilizado para a construção da EDA completa desta etapa:

Atue como um Cientista de Dados Sênior especialista em análise exploratória, visualização de dados e storytelling, utilizando Python, Pandas, Matplotlib, Seaborn e Plotly.

Quero que você realize toda a EDA da Semana 3.1 com base no arquivo `spotify_semana2_tratado.csv`, seguindo rigorosamente as etapas abaixo:

1. Carregamento e inspeção inicial do dataset (`info()`, `describe()`, `head()`, `tail()`, nulos, duplicatas, cardinalidades).
2. Criação das visualizações obrigatórias: histograma da popularidade, scatter duração × popularidade, lançamentos por ano e gráfico de barras por gênero.
3. Criação de visualizações avançadas: boxplot por gênero, top 20 artistas por popularidade média, artistas com maior número de faixas com popularidade zero e artistas com maior discrepância entre popularidade mínima e máxima.
4. Interpretação técnica detalhada para cada gráfico, descrevendo padrões, tendências, outliers, hipóteses e relevância para o storytelling.
5. Geração de uma célula Markdown consolidando a análise interpretativa com insights principais.
6. Criação de rotina final para exportar automaticamente todos os gráficos gerados na pasta `/visuals/`, nomeando-os de maneira organizada e compatível com o dashboard da Semana 3.3.

2.2 Execução da Análise Exploratória dos Dados

A partir do prompt, executou-se toda a EDA da Semana 3.1, composta pelas seguintes etapas:

a) Carregamento e inspeção do dataset

Uso de `df.info()`, `df.describe()`, `df.head()` e `df.tail()`;

Identificação de 1.458 faixas sem valores ausentes nem duplicidades;

Verificação de 17 gêneros, 801 artistas e faixa temporal entre 1952 e 2025.

b) Visualizações obrigatórias

Foram construídos:

Histograma da popularidade (com e sem popularidade zero);

Scatterplot duração × popularidade, diferenciando faixas zero;

Distribuição de lançamentos por ano, exibindo crescimento exponencial pós-2010;

Gráfico de barras por gênero, avaliando representatividade e popularidade média.

c) Visualizações avançadas

Para enriquecer a análise, foram incluídos gráficos adicionais:

Boxplot da popularidade por gênero (variabilidade e consistência);

Top 20 artistas por popularidade média;

Top 20 artistas com maior número de faixas de popularidade zero;

Artistas com maior discrepância de popularidade (máx – mín).

Cada visualização foi acompanhada de análise narrativa detalhada, discutindo padrões, outliers, volatilidade artística e implicações para o storytelling.

d) Consolidação da EDA

A análise interpretativa foi reunida em uma célula Markdown (Célula 23), contendo: descrição técnica, insights culturais e mercadológicos, impacto para fases posteriores, conclusões estruturadas.

e) Exportação automatizada dos gráficos

Uma rotina profissional (Célula 24) foi implementada para: identificar todas as figuras geradas, classificá-las por categoria, salvá-las em /visuals/, nomeá-las de modo descritivo, organizá-las em subpastas (plots, boxplots, faixas_zero, discrepancias, top_artistas).

3 RESULTADOS

Os principais achados da EDA incluem:

Distribuição bimodal da popularidade, com grande concentração de faixas zero.

Domínio dos gêneros Latin, Pop e Indie na popularidade média.

Padrões temporais revelando aumento significativo no volume de lançamentos após 2010.

Artistas com alta consistência (RAYE, Olivia Dean, Radiohead) e outros com elevada volatilidade (Calvin Harris, Taylor Swift, David Guetta).

Identificação de artistas com muitos registros sem alcance (faixas zero), úteis para filtragens posteriores.

Esses insights alimentam diretamente a próxima issue: Semana 3.3 — Storytelling & Protótipo de Dashboard.

4 CONSIDERAÇÕES FINAIS

A primeira issue da Semana 3 atingiu integralmente seus objetivos. Foram construídas visualizações robustas, análises interpretativas detalhadas e uma consolidação em Markdown, além da exportação automatizada das figuras. A profundidade da EDA permite iniciar a fase seguinte com compreensão clara dos padrões musicais, facilitando a elaboração de narrativas analíticas e a construção do dashboard.

A próxima issue (3.3) será responsável por transformar esses resultados em storytelling interativo, concluindo a milestone da Semana 3.

FAC SENAC DF – Curso de Ciência de Dados
Projeto Interdisciplinar: Análise de Dados com Python, IA e Engenharia de Prompt
Relatório Técnico – Semana 3 (12 de novembro de 2025)
Aluno: Anderson de Matos Guimarães
Professor: Alexsander Barreto
Instituição: Faculdade de Tecnologia e Inovação Senac DF
Conta Google utilizada nesta semana: anderson.m.guimaraes@icloud.com

1 INTRODUÇÃO

A segunda etapa da Semana 3 (Issue 3.2) teve como objetivo transformar os resultados da Análise Exploratória dos Dados (executada na Issue 3.1) em um processo interpretativo estruturado, conectando achados estatísticos a narrativas analíticas, hipóteses culturais, padrões mercadológicos e comportamentos típicos do consumo musical em plataformas digitais.

A partir das visualizações produzidas anteriormente, esta etapa buscou interpretar tendências, correlações, volatilidades, consistências e padrões de engajamento, preparando o terreno para a construção do storytelling e do protótipo de dashboard que serão desenvolvidos na Issue 3.3.

O trabalho foi conduzido em Google Colab, utilizando bibliotecas Python voltadas à análise interpretativa. A Engenharia de Prompt orientou a produção da análise narrativa, garantindo completude e clareza metodológica.

2. PROMPT UTILIZADO PARA EXECUÇÃO DA ISSUE 3.2

Conforme exigido pelo professor, segue abaixo o prompt integral utilizado para orientar esta etapa do projeto:

Atue como um Cientista de Dados Sênior, especialista em análise interpretativa, storytelling com dados, estatística descritiva e análise cultural/mercadológica aplicada ao mercado musical.

Com base nas visualizações e análises produzidas na Semana 3.1 (EDA), quero que você realize a Issue da Semana 3.2, seguindo rigorosamente as etapas abaixo.

1. Interpretação Estatística Avançada

Análise profundamente as variáveis numéricas do dataset (popularidade, duracao_min, ano_lancamento e derivadas).

Descreva tendências centrais, dispersões, outliers, implicações culturais e hipóteses relacionadas ao comportamento do usuário e à indústria fonográfica.

2. Tendências e Correlações

Avalie possíveis relações entre popularidade, duração, ano e gênero.

Interprete se faixas mais recentes são mais populares, se músicas mais curtas engajam mais, e como os gêneros se diferenciam.

3. Classificação de Padrões

Classifique padrões relevantes por artista, gênero, período ou subcategorias (faixas zero, artistas voláteis, catálogos consistentes).

Produza uma tabela-resumo dos principais padrões.

4. Interpretação das Visualizações da EDA

Para cada gráfico criado na Issue 3.1, interprete o que ele significa, quais fenômenos revela, e quais hipóteses explicam tais comportamentos.

5. Análise Narrativa Final

Elabore um texto fluido, técnico e profissional com interpretações, implicações mercadológicas, hipóteses e aplicações práticas para o storytelling e dashboard.

6. Insights Culturais e Mercadológicos

Explique o que as tendências encontradas revelam sobre padrões culturais de consumo musical.

7. Entrega Consolidada

Produza:

1. Um bloco Markdown único para o relatório técnico.
2. Um resumo executivo com os pontos-chave da análise.

3. DESENVOLVIMENTO DAS ATIVIDADES

A execução do prompt resultou em um conjunto estruturado de análises, organizadas conforme as etapas previstas:

3.1 Interpretação Estatística das Variáveis Numéricas

Foram analisadas:

- popularidade: bimodal, com forte concentração em “zero” e outro grupo entre 60 e 85 pontos;
- duracao_min: distribuição centrada em ~3,5 min, coerente com padrões de consumo em streaming;
- ano_lancamento: forte concentração pós-2010, com pico em 2024;
- popularidade_norm: seguiu padrão semelhante à popularidade original.
- A interpretação relacionou esses achados à dinâmica do Spotify, discutindo:
- long tail de faixas sem engajamento,
- preferência por músicas curtas,
- explosão de lançamentos recentes,
- comportamento algorítmico de recomendações.

3.2 Identificação de Tendências e Correlações

A partir das visualizações da Issue 3.1:

- foi observada correlação positiva fraca entre ano de lançamento e popularidade — indicando maior consumo de faixas recentes;
- identificou-se que faixas mais curtas tendem a ocupar o grupo mais popular, embora sem correlação linear forte;
- verificou-se diferenças significativas entre gêneros, com destaque para Latin, Pop e Indie;
- analisou-se a volatilidade por artista, observando casos de extrema discrepância dentro do catálogo.

3.3 Classificação de Padrões Relevantes

Os padrões foram classificados em quatro eixos:

- por artista (consistentes, voláteis, com muitos registros zero);

- por gênero (mainstream vs. nichados);
- por período histórico (pré-2000, 2000–2010, pós-2010);
- por comportamento de engajamento (zero, médio, alto).

Uma tabela-resumo foi elaborada, sintetizando padrões centrais.

3.4 Interpretação Direta das Visualizações da EDA

Em vez de descrever os gráficos novamente, a análise focou exclusivamente em interpretar fenômenos, como:

- o efeito da saturação de faixas zero,
- a curva crescente de lançamentos,
- dispersões características por gênero,
- padrões de “faixa ideal” em 3–4 minutos,
- volatilidade do catálogo de artistas com grande amplitude de popularidade.

Cada gráfico foi articulado com hipóteses e práticas da indústria musical.

3.5 Construção da Análise Narrativa Final

A análise consolidada abordou:

- desigualdade de engajamento (“poucas faixas puxam o todo”),
- força dos gêneros globais,
- impacto da duração curta,
- volatilidade por artista,
- estrutura temporal pós-2010.

Essa narrativa está registrada na Célula 25, totalmente revisada e otimizada para evitar redundâncias com a Célula 23.

3.6 Insights Culturais e Mercadológicos

Foram identificadas implicações como:

- necessidade de estratégias focadas em back catalogue,

- fortalecimento de gêneros globais na construção de campanhas,
- padrões de descoberta musical no Spotify,
- importância de segmentação de artistas por consistência ou volatilidade.

3.7 Entrega Consolidada

A Issue foi concluída com:

- Célula 25 (Markdown) contendo a análise interpretativa completa;
- Resumo executivo;
- Integração plena com os resultados da Issue 3.1;
- Preparação direta para o storytelling visual e dashboard da Issue 3.3.

4. RESULTADOS OBTIDOS

A análise interpretativa permitiu:

- compreender padrões estruturais do dataset;
- identificar forças e fraquezas dos gêneros musicais;
- avaliar consistência e instabilidade de artistas;
- consolidar narrativas essenciais para o dashboard;
- estabelecer hipóteses alinhadas a práticas reais de mercado;
- transformar a EDA bruta em conhecimento acionável.

Este conjunto de análises agrega profundidade ao storytelling e dá suporte ao protótipo que será criado na próxima issue.

5. CONSIDERAÇÕES FINAIS

A Issue 3.2 atingiu integralmente seus objetivos, convertendo resultados quantitativos em narrativa de valor interpretativo e mercadológico. A Célula 25 sintetiza esse processo com rigor técnico e clareza metodológica.

Este conteúdo permitirá avançar para a Issue 3.3 com entendimento profundo dos padrões musicais, gerando um dashboard mais coerente, interpretativo e orientado a decisões.

1. INTRODUÇÃO

A Issue 3.3 marcou a etapa de transformação das análises quantitativas e interpretativas realizadas nas Issues 3.1 (EDA) e 3.2 (Storytelling Analítico) em um protótipo funcional de dashboard interativo. Essa fase estabeleceu a ponte entre os resultados da investigação de dados e sua apresentação em formato visual, navegável e orientado a usuários.

O objetivo principal foi construir uma interface inicial que reunisse os principais insights do dataset e permitisse exploração dinâmica das métricas de popularidade, gêneros, artistas e evolução temporal no Spotify. Essa versão será expandida e refinada na Semana 4 para compor o dashboard final.

2. PROMPT UTILIZADO NA EXECUÇÃO DA ISSUE 3.3

Conforme solicitado pelo professor, segue o prompt integral utilizado para realizar a atividade:

Atue como um Cientista de Dados Sênior, especialista em Storytelling Visual, Design de Dashboards e prototipação rápida usando ferramentas como Lovable, Streamlit ou Bolt.

Agora quero que você desenvolva o PROTÓTIPO INICIAL DO DASHBOARD da Semana 3, integrando as análises e visualizações que construímos nas Issues 3.1 e 3.2.

Siga rigorosamente as etapas abaixo.

1. Escolha da ferramenta de prototipação
2. Seleção das visualizações essenciais
3. Definição do storytelling visual
4. Inserção das visualizações no protótipo

5. Bloco de storytelling automático dentro do dashboard
 6. Garantir design limpo e intuitivo
 7. Gerar o protótipo final exportável
 8. Redigir o texto de documentação para o relatório técnico
- Cumprir TODAS AS ETAPAS acima.

3. DESENVOLVIMENTO DAS ATIVIDADES

A execução da Issue 3.3 ocorreu em três frentes principais: seleção da ferramenta, desenvolvimento do protótipo e documentação no notebook.

3.1 Escolha da Ferramenta

Após comparar Lovable, Bolt e Streamlit, a solução escolhida foi:

Streamlit – pela capacidade de integrar Python, Plotly e interatividade em uma interface simples, modular e de rápida prototipação.

Foi considerada a ferramenta mais adequada para:

- manter o fluxo do notebook,
- permitir reprodutibilidade,
- criar um dashboard flexível com abas,
- facilitar a avaliação e evolução do protótipo.

3.2 Desenvolvimento do Arquivo `spotify_dashboard_app.py`

Foi criado o arquivo `spotify_dashboard_app.py` contendo toda a estrutura do dashboard, utilizando:

- abas temáticas (Visão Geral, Gêneros, Artistas, Linha do Tempo),
- KPIs importantes,
- filtros interativos,
- gráficos Plotly dinâmicos,
- explicações narrativas,
- storytelling inicial dentro da própria interface.

O código foi gerado e salvo no ambiente utilizando a Célula 27, revisado para evitar erros Unicode e garantir a integridade do arquivo .py.

3.3 Estrutura e Funcionalidades do Protótipo

O dashboard foi organizado em quatro abas principais:

Aba 1 – Visão Geral

- histograma de popularidade
- dispersão duração × popularidade
- KPIs: total filtrado, popularidade média, % de faixas zero, duração média

Aba 2 – Gêneros

- boxplot de popularidade por gênero
- tabela estatística descritiva

Aba 3 – Artistas

- top artistas por média de popularidade
- artistas com maior discrepância
- artistas com maior quantidade de faixas zero

Aba 4 – Linha do tempo

- lançamentos por ano
- leitura interpretativa sobre tendências temporal-musicais
- Além disso, foram implementados filtros interativos:
- multiselect de gêneros
- controle de período de anos
- controle de popularidade mínima

Esses filtros permitem ao usuário explorar padrões específicos e construir análises próprias.

3.4 Documentação no Notebook

A Célula 26 documenta a criação do protótipo e seus objetivos.

A Célula 27 salva o arquivo .py no ambiente, permitindo commit para o GitHub.

Essa organização garante rastreabilidade, execução reprodutível e documentação clara do fluxo de trabalho.

4. RESULTADOS OBTIDOS

A Issue 3.3 foi concluída com a criação de um protótipo funcional, navegável e coerente com o storytelling da Semana 3. O dashboard já apresenta:

- interatividade completa,
- insights integrados,
- visualização clara do comportamento das variáveis,
- base sólida para evolução, refinamento visual e narrativa interativa na Semana 4.

O protótipo cumpre o papel de consolidar e comunicar o aprendizado obtido nas etapas anteriores.

5. CONCLUSÃO

A Issue 3.3 foi entregue em 14/11/2025, cumprindo inteiramente as exigências da Semana 3.

O dashboard criado fornece uma estrutura robusta para o desenvolvimento da versão final e demonstra:

- domínio das ferramentas de visualização,
- integração entre análise estatística e storytelling,
- organização de dados em uma interface interativa,
- capacidade de transformar análises em produtos exploráveis.

O resultado representa um avanço significativo na transformação das análises em insights visualmente acessíveis.