

ANDERSON DE MATOS GUIMARÃES

**SPOTIFY DATA STORYTELLING:
ANÁLISE EXPLORATÓRIA, INTERPRETATIVA E DESENVOLVIMENTO DE UM
DASHBOARD INTERATIVO BASEADO EM INTELIGÊNCIA ARTIFICIAL**

BRASÍLIA
2025

ANDERSON DE MATOS GUIMARÃES

**SPOTIFY DATA STORYTELLING:
ANÁLISE EXPLORATÓRIA, INTERPRETATIVA E DESENVOLVIMENTO DE UM
DASHBOARD INTERATIVO BASEADO EM INTELIGÊNCIA ARTIFICIAL**

Relatório Técnico apresentado como requisito parcial para avaliação das disciplinas Deep Learning e Laboratório de Inovação IV, do quarto semestre do curso de Tecnologia em Ciência de Dados da Faculdade de Tecnologia e Inovação Senac DF.

Orientador: Alexsander Holanda Barreto

BRASÍLIA
2025

ANDERSON DE MATOS GUIMARÃES

**SPOTIFY DATA STORYTELLING:
ANÁLISE EXPLORATÓRIA, INTERPRETATIVA E DESENVOLVIMENTO DE UM
DASHBOARD INTERATIVO BASEADO EM INTELIGÊNCIA ARTIFICIAL**

Relatório Técnico apresentado como requisito parcial para avaliação das disciplinas Deep Learning e Laboratório de Inovação IV, do quarto semestre do curso de Tecnologia em Ciência de Dados da Faculdade de Tecnologia e Inovação Senac DF.

Aprovado em: ____/____/____.

BANCA EXAMINADORA

Prof. Alexsander Holanda Barreto
Faculdade de Tecnologia e Inovações Senac DF

Dedico este trabalho à minha família, pelo apoio incondicional, pela força diária e por acreditarem no meu percurso acadêmico e profissional.

Cada conquista alcançada é resultado do amor, incentivo e presença constante de vocês.

AGRADECIMENTOS

Agradeço primeiramente a Deus, pela força e sabedoria concedidas ao longo de toda esta jornada acadêmica.

Aos meus familiares, pelo apoio incondicional, incentivo diário e compreensão nos momentos de estudo e dedicação intensa.

Expresso minha gratidão ao professor Alexsander Holanda Barreto, cuja orientação, atenção e domínio técnico contribuíram de maneira essencial para o desenvolvimento deste trabalho. Sua postura profissional e seu comprometimento com o ensino foram fundamentais para meu crescimento como estudante e futuro profissional de Ciência de Dados.

Agradeço também à Faculdade de Tecnologia e Inovação Senac-DF, por proporcionar um ambiente de aprendizagem de excelência e pela estrutura que torna possível o desenvolvimento de projetos relevantes e conectados à prática do mercado.

Por fim, deixo meu reconhecimento a todos os colegas de curso que, direta ou indiretamente, contribuíram com insights, discussões e apoio mútuo durante o processo. Cada contribuição fortaleceu não apenas este trabalho, mas meu percurso formativo como um todo.

“Sem dados, você é apenas mais uma
pessoa com opinião.”

(W. Edwards Deming)

RESUMO

Este relatório técnico apresenta o desenvolvimento integral do projeto Spotify Data Storytelling, estruturado em quatro semanas de atividades que abrangeram: análise exploratória de dados (EDA), análise interpretativa orientada por storytelling, geração de insights automáticos via IA generativa e construção de um dashboard interativo em Streamlit. O dataset utilizado, contendo milhares de faixas musicais do Spotify, permitiu investigar padrões de popularidade, duração, distribuição temporal, comportamento de gêneros e discrepâncias entre artistas. Todo o desenvolvimento foi conduzido com apoio de engenharia de prompt aplicada e técnicas de Data Science, culminando na publicação de um dashboard final acessível online. O relatório consolida todas as atividades semanais, resultados, códigos, gráficos, interpretações e prompts utilizados no processo.

Palavras-chave: Spotify; Ciência de Dados; EDA; Streamlit; IA generativa; engenharia de prompt; dashboard; análise musical.

ABSTRACT

This technical report presents the integral development of the Spotify Data Storytelling project, structured in four weeks of activities that covered: exploratory data analysis (EDA), interpretive analysis guided by storytelling, generation of automatic insights via generative AI and construction of an interactive dashboard in Streamlit. The dataset used, containing thousands of Spotify music tracks, allowed us to investigate patterns of popularity, duration, temporal distribution, genre behavior, and discrepancies between artists. The entire development was conducted with the support of applied prompt engineering and Data Science techniques, culminating in the publication of a final dashboard accessible online. The report consolidates all weekly activities, results, codes, graphs, interpretations, and prompts used in the process.

Keywords: Spotify; Data Science; EDA; Streamlit; Generative AI; prompt engineering; dashboard; Music analysis.

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Problema	12
1.2	Objetivos	13
1.2.1	<i>Objetivo geral</i>	13
1.2.2	<i>Objetivos específicos</i>	13
1.3	Justificativa	14
1.3.1	<i>Relevância científica e tecnológica</i>	14
1.3.2	<i>Relevância social e cultural</i>	14
1.3.3	<i>Relevância prática e profissional</i>	14
1.4	Estrutura do relatório	15
2	METODOLOGIA	16
2.1	Abordagem geral	16
2.2	Etapas do Processo Analítico	16
2.2.1	<i>Coleta de dados (API Spotify)</i>	17
2.2.2	<i>Tratamento e padronização dos dados</i>	17
2.2.3	<i>Análise exploratória dos dados (EDA)</i>	17
2.2.5	<i>Integração com IA Generativa</i>	18
2.2.6	<i>Construção do dashboard em Streamlit</i>	19
2.2.7	<i>Deploy</i>	19
2.3	<i>Ferramentas Utilizadas</i>	19
2.4	Organização das Issues por Semana	20
2.5	Uso da IA Generativa no projeto	20
2.6	Estrutura dos prompts no relatório	21
3	DESENVOLVIMENTO POR SEMANA	22
3.1	Semana 1 – Ambientação no Google Colab e Engenharia de Prompt	22
3.1.1	<i>Atividades desenvolvidas</i>	22
3.1.2	<i>Prompts utilizados na Semana 1</i>	23
3.1.2.1	<i>Prompt 1 – Planejamento do relatório (mestre):</i>	23
3.1.2.2	<i>Prompt 2 – Guia de criação e uso do Colab (zero-shot):</i>	23
3.1.2.3	<i>Prompt 3 – Engenharia de Prompt (few-shot):</i>	23
3.1.2.4	<i>Prompt 4 – Troubleshooting (chain-of-thought):</i>	23

3.2	Semana 2 – coleta, limpeza e transformação de dados via API do Spotify	24
3.2.1	Atividades desenvolvidas	24
3.2.2	Prompts utilizados na Semana 2	24
3.2.2.1	<i>Prompt 1 — Coleta estruturada (few-shot):</i>	25
3.2.2.2	<i>Prompt 2 — Diagnóstico de qualidade (chain-of-thought):</i>	25
3.2.2.3	<i>Prompt 3 — Relatório narrativo (zero-shot):</i>	25
3.3	Semana 3 – EDA, análise interpretativa e protótipo de dashboard	25
3.3.1	Issue 3.1 – Análise Exploratória dos Dados (EDA)	25
3.3.1.1	<i>Atividades desenvolvidas</i>	25
3.3.1.2	<i>Prompt utilizado na Issue 3.1</i>	26
3.3.2	Issue 3.2 – análise Interpretativa e storytelling analítico	27
3.3.2.1	<i>Atividades desenvolvidas</i>	27
3.3.2.2	<i>Prompt utilizado na Issue 3.2</i>	27
3.3.3	Issue 3.3 – Protótipo Inicial do Dashboard Interativo	29
3.3.3.1	<i>Atividades desenvolvidas</i>	29
3.3.3.2	<i>Prompt utilizado na Issue 3.3</i>	29
3.4	Semana 4 – insights automáticos com IA e dashboard final	30
3.4.1	Issue 4.1 – Integração de Insights Automáticos com IA	30
3.4.1.1	<i>Atividades desenvolvidas</i>	30
3.4.1.2	<i>Prompt utilizado na Issue 4.1</i>	31
3.4.2	Issue 4.2 – dashboard final, integração IA ↔ dashboard e deploy	32
3.4.2.1	<i>Atividades desenvolvidas</i>	32
3.4.2.2	<i>Prompt utilizado na Issue 4.2</i>	33
4	DASHBOARD INTERATIVO	35
4.1	Arquitetura do dashboard	35
4.1.1	Camada de Dados	35
4.1.2	Camada Analítica	35
4.1.3	Camada Visual/Interativa	35
4.2	Estrutura geral da interface	36
4.2.1	Aba “Visão Geral”	36
4.2.2	Aba “Gêneros Musicais”	36
4.2.3	Aba “Artistas”	37
4.2.4	Aba “Linha do Tempo”	37

4.3	Filtros Interativos	38
4.4	KPIs e Indicadores Dinâmicos	38
4.5	Integração com IA Generativa	38
4.5.1	<i>Insights Automáticos</i>	38
4.5.2	<i>Storytelling Automático</i>	39
4.5.3	<i>Sugestões IA-driven</i>	39
4.6	<i>Arquitetura de API (Modelo Conceitual)</i>	39
4.7	Preparação para Deploy	40
4.8	Considerações sobre design e usabilidade	40
5	RESULTADOS E DISCUSSÃO	42
5.1	Padrões gerais do dataset	42
5.2	Popularidade: distribuição, cauda longa e consistência	42
5.2.1	<i>Distribuição geral</i>	42
5.2.2	<i>Faixas “zero popularidade”</i>	43
5.2.3	<i>Consistência da popularidade</i>	43
5.3	Gêneros musicais: desempenho, variabilidade e nichos	43
5.3.1	<i>Popularidade média por gênero</i>	44
5.3.2	<i>Boxplot por gênero</i>	44
5.3.3	<i>Insights culturais</i>	44
5.4	Artistas: volume, volatilidade e padrões de catálogo	44
5.4.1	<i>Top 20 artistas por popularidade média</i>	45
5.4.2	<i>Volatilidade de catálogo</i>	45
5.4.3	<i>Artistas com mais faixas zero</i>	45
5.5	Análise temporal: tendências históricas	45
5.5.1	<i>Crescimento pós-2010</i>	46
5.5.2	<i>Relação ano × popularidade</i>	46
5.5.3	<i>Hipóteses interpretativas</i>	46
5.6	Duração das faixas: tendências e comportamento	46
5.7	Integração IA + storytelling: contribuições relevantes	47
5.7.1	<i>Insights automáticos</i>	47
5.7.2	<i>Textos explicativos integrados ao dashboard</i>	47
5.7.3	<i>Sugestões avançadas</i>	47
5.8	Síntese dos principais achados	47
	CONCLUSÃO	49

REFERÊNCIAS	51
APÊNDICE A – Prompts utilizados	52

1 INTRODUÇÃO

Nas últimas décadas, o consumo musical passou por profundas transformações impulsionadas pela digitalização, pela disseminação de dispositivos móveis e pela consolidação dos serviços de streaming. Entre essas plataformas, o Spotify se destaca como líder global, reunindo centenas de milhões de usuários ativos mensais e uma base expressiva de assinantes premium (SPOTIFY TECHNOLOGY S.A., 2024). Além de sua relevância comercial, o Spotify se consolidou como um dos maiores provedores de dados culturais do mundo, disponibilizando metadados detalhados sobre faixas, artistas, gêneros, níveis de popularidade e padrões temporais de lançamentos.

Esse volume de dados possibilita análises ricas e multifacetadas sobre comportamento de usuários, tendências de mercado, dinâmicas de consumo musical e relações culturais mediadas por algoritmos de recomendação. A extração dessas informações, viabilizada pela API pública do Spotify, permite que pesquisadores, analistas e desenvolvedores explorem recursos avançados para diagnóstico, previsão e visualização interativa, integrando Ciência de Dados, engenharia de software e narrativas apoiadas em Inteligência Artificial (IA).

O presente trabalho, desenvolvido no âmbito das disciplinas Deep Learning e Laboratório de Inovação IV do curso Tecnologia em Ciência de Dados da Faculdade de Tecnologia e Inovação Senac-DF (4º semestre), consiste na construção de um pipeline completo de Data Storytelling utilizando Python, Pandas, Plotly, IA generativa e Streamlit. O objetivo central é transformar dados brutos coletados via API em visualizações interativas, métricas interpretáveis e insights orientados por IA, culminando em um dashboard analítico moderno, acessível e alinhado às demandas contemporâneas de análise de dados.

1.1 Problema

Apesar da abundância de dados disponibilizados pela API do Spotify, observa-se que, em muitos contextos acadêmicos e profissionais, esses recursos ainda são subaproveitados quando o objetivo é integrar, de forma estruturada, análise quantitativa, visualização e storytelling. Com frequência, o uso se restringe a descrições básicas ou gráficos pontuais, sem um fluxo completo que articule:

- a) coleta automatizada e segura dos dados;
- b) limpeza e padronização;
- c) exploração visual interativa;
- d) geração de insights automatizados com apoio de IA;
- e) e deploy acessível do produto analítico final.

O problema central deste trabalho, portanto, consiste em estruturar um fluxo de análise de dados musicais de ponta a ponta, desde a coleta via API e o tratamento dos dados até a comunicação visual e a disponibilização pública dos resultados em um dashboard interativo, utilizando ferramentas modernas de Ciência de Dados e Inteligência Artificial.

1.2 Objetivos

1.2.1 Objetivo geral

Construir um dashboard interativo, informativo e responsivo, baseado em dados musicais do Spotify, que permita ao usuário explorar padrões de popularidade, gêneros, artistas, temporalidade e comportamentos característicos do catálogo analisado, integrando técnicas de análise de dados, visualização e IA generativa.

1.2.2 Objetivos específicos

Coletar dados musicais utilizando a API pública do Spotify, respeitando boas práticas de autenticação segura e organização do código.

Realizar limpeza, padronização e enriquecimento do dataset, com criação de novas variáveis e métricas analíticas relevantes.

Desenvolver análises exploratórias e visualizações interativas com Pandas e Plotly.

Implementar narrativas guiadas por IA para apoiar a interpretação dos resultados e a produção de textos analíticos.

Construir um dashboard em Streamlit com múltiplas abas, filtros dinâmicos e interatividade completa.

Hospedar o dashboard em ambiente online acessível ao público e ao professor, garantindo reprodutibilidade do experimento.

Documentar todo o processo, incluindo a forma de uso da IA generativa e os prompts empregados nas diferentes etapas do fluxo analítico.

1.3 Justificativa

A relevância deste trabalho se fundamenta em três dimensões principais: científica e tecnológica, social e cultural, e prática e profissional.

1.3.1 Relevância científica e tecnológica

A análise de dados musicais oferece um campo fértil para a aplicação de técnicas de Ciência de Dados, envolvendo estatística descritiva, visualização, engenharia de dados, automação de processos e uso de IA generativa. Trabalhar com um caso real, baseado em uma grande plataforma de streaming, contribui para aproximar o estudante de problemas concretos e do uso integrado de bibliotecas, APIs e frameworks, fortalecendo competências essenciais à formação em Tecnologia em Ciência de Dados.

1.3.2 Relevância social e cultural

O Spotify influencia diretamente hábitos culturais, modos de consumo e dinâmicas de produção musical, impactando a indústria fonográfica global e os modos como artistas e público se relacionam. Compreender padrões de popularidade, gêneros em destaque, comportamentos de escuta e sazonalidades permite analisar transformações culturais contemporâneas a partir de evidências empíricas, contribuindo para uma leitura mais crítica do consumo musical mediado por plataformas digitais.

1.3.3 Relevância prática e profissional

O uso de APIs, a construção de dashboards e a integração com IA generativa refletem práticas adotadas por empresas de tecnologia, startups de dados, áreas de marketing digital, plataformas de recomendação e equipes de business intelligence. Dominar esse pipeline, da coleta ao deploy, aproxima o estudante das exigências

atuais do mercado de trabalho, ao mesmo tempo em que desenvolve habilidades de documentação, reprodutibilidade e comunicação visual de resultados.

Dessa forma, o trabalho combina relevância conceitual, metodológica e aplicada, resultando em uma entrega concreta, tecnicamente robusta e alinhada às competências esperadas nas disciplinas envolvidas.

1.4 Estrutura do relatório

O relatório está organizado nas seguintes seções:

Capítulo 1 – Introdução: contextualização teórica, formulação do problema, definição dos objetivos e justificativa do estudo.

Capítulo 2 – Metodologia: descrição dos métodos, das bibliotecas utilizadas, do fluxo analítico, das ferramentas empregadas e da forma de utilização da IA generativa, incluindo exemplos dos prompts aplicados.

Capítulo 3 – Desenvolvimento por Semana: detalhamento das atividades realizadas ao longo das quatro semanas do projeto, apresentando, para cada etapa, o código principal, os resultados obtidos, os artefatos gerados e os prompts associados às issues correspondentes.

Capítulo 4 – Dashboard Interativo: apresentação da arquitetura do sistema, das funcionalidades implementadas, dos filtros, das abas e das características de design do dashboard final em Streamlit.

Capítulo 5 – Resultados e Discussão: sistematização das principais análises, padrões identificados, interpretações e contribuições da IA generativa no processo de storytelling.

Capítulo 6 – Conclusões: síntese dos achados, limitações do estudo, possibilidades de melhoria e perspectivas de trabalhos futuros.

Referências: listagem das obras e materiais consultados, conforme normas da ABNT.

Apêndices: materiais suplementares, incluindo a versão integral dos prompts utilizados e outros documentos de apoio, quando necessário.

2 METODOLOGIA

Este capítulo descreve o conjunto de métodos, técnicas, ferramentas e fluxos adotados para o desenvolvimento do projeto Spotify Data Storytelling, contemplando desde a coleta dos dados via API até a construção e publicação do dashboard interativo. A metodologia integra princípios da Ciência de Dados, práticas de engenharia de software, uso de bibliotecas consolidadas em Python e apoio sistemático de Inteligência Artificial generativa para acelerar etapas do processo e aprimorar a qualidade das entregas.

2.1 Abordagem geral

A abordagem metodológica adotada neste projeto segue um fluxo completo de análise de dados, estruturado de forma sequencial e iterativa:

- a) coleta de Dados via API do Spotify
- b) tratamento, normalização e enriquecimento do dataset
- c) análise Exploratória dos Dados (EDA)
- d) geração de visualizações interativas
- e) construção de insights narrativos assistidos por IA
- f) desenvolvimento de dashboard em Streamlit
- g) deploy e documentação final

Esse fluxo reflete práticas consolidadas em projetos reais de Data Science e está alinhado ao objetivo central do trabalho: integrar storytelling, análise estatística, visualização e automação baseada em IA.

2.2 Etapas do Processo Analítico

O desenvolvimento do projeto foi organizado em quatro semanas, seguindo as issues propostas pelo professor. Em cada semana foram realizadas atividades específicas, descritas no Capítulo 3. Aqui apresentamos a visão metodológica geral, etapa por etapa.

2.2.1 Coleta de dados (API Spotify)

A API pública do Spotify foi utilizada para extrair informações sobre artistas, faixas, álbuns e métricas musicais. A metodologia incluiu:

- a) uso do método Client Credentials Flow para autenticação;
- b) armazenamento seguro das credenciais com python-dotenv;
- c) construção de funções em Python para acessar endpoints;
- d) conversão das respostas JSON em estruturas Pandas;
- e) unificação dos datasets em estruturas analíticas.

A escolha pela API do Spotify se justifica pela sua riqueza informacional e pela possibilidade de construir análises culturais, temporais e estatísticas baseadas em dados reais.

2.2.2 Tratamento e padronização dos dados

Após a coleta, o dataset passou por um processo de preparação, incluindo:

- a) remoção de nulos e duplicados;
- b) padronização de nomenclaturas de colunas;
- c) transformação de listas em colunas estruturadas (ex.: gêneros);
- d) criação de novas variáveis, como contagem de gêneros, análise temporal e categorização de popularidade.

Essa etapa assegura qualidade, consistência e usabilidade analítica do dataset, conforme boas práticas da engenharia de dados.

2.2.3 Análise exploratória dos dados (EDA)

A análise exploratória foi conduzida com apoio das bibliotecas:

- a) Pandas – manipulação tabular;
- b) NumPy – cálculos matemáticos;
- c) Plotly Express e Graph Objects – visualizações interativas;
- d) Seaborn/Matplotlib – gráficos suplementares.

Foram produzidas análises como:

- a) distribuição de popularidade;
- b) frequência de gêneros;

- c) artistas mais relevantes;
- d) evolução temporal de lançamentos;
- e) mapas interativos com distribuição global de dados;
- f) gráficos de barras, linhas, dispersão e mapas coropléticos.

2.2.4 Visualizações Interativas

As visualizações foram desenvolvidas com Plotly, por sua capacidade de:

- a) gerar gráficos modernos e responsivos;
- b) permitir interações (hover, zoom, seleção);
- c) se integrar nativamente ao Streamlit.

Foram criados, entre outros:

- a) choropleths;
- b) scatter_geo;
- c) histogramas;
- d) análises comparativas por popularidade;
- e) linhas temporais.

A identidade visual priorizou clareza, contraste e navegabilidade.

2.2.5 Integração com IA Generativa

A Inteligência Artificial (ChatGPT) desempenhou papel importante em diferentes fases:

- a) acelerar o desenvolvimento de código em Python;
- b) apoiar decisões de modelagem e limpeza de dados;
- c) gerar análises narrativas;
- d) revisar textos do relatório;
- e) sugerir melhorias visuais;
- f) detectar erros em células do notebook;
- g) auxiliar no refinamento do app.py.

A IA foi utilizada como assistente, não como substituta da autoria analítica.

No Capítulo 3, cada atividade inclui o prompt utilizado correspondente.

2.2.6 Construção do dashboard em Streamlit

A interface foi desenvolvida com Streamlit, devido à sua sintaxe simples, desempenho eficiente e capacidade de integrar:

- a) múltiplas abas;
- b) filtros dinâmicos;
- c) gráficos Plotly;
- d) estatísticas agregadas;
- e) componentes interativos.

O app foi estruturado em:

- a) Visão Geral — métricas principais e distribuição geral;
- b) Artistas — popularidade, seguidores, gêneros associados;
- c) Faixas — ranking, duração, métricas musicais;
- d) Gêneros — frequências, mapas, relevância regional;
- e) Linha Temporal — análise por anos e períodos.

O design priorizou acessibilidade, responsividade e fluidez da navegação.

2.2.7 Deploy

Foram testadas duas alternativas:

- a) Streamlit Cloud – rápida, integrada e prática;
- b) Vercel – exigiu ajustes em requirements e estrutura de pastas.

A solução final adotada foi otimizada para permitir acesso público ao dashboard, facilitando avaliação e reprodutibilidade.

2.3 Ferramentas Utilizadas

As principais ferramentas e bibliotecas utilizadas foram:

Categoria	Ferramenta
Linguagem	Python 3.11
Ambiente de desenvolvimento	VS Code, Google Colab
Manipulação de dados	Pandas, NumPy
Visualizações	Plotly, Matplotlib, Seaborn
API	Spotify Web API
Integração com IA	ChatGPT
Dashboard	Streamlit

Categoria	Ferramenta
Controle de versão	GitHub
Deploy	Streamlit Cloud / Vercel
Documentação	ABNT, Markdown

2.4 Organização das Issues por Semana

O trabalho foi estruturado em quatro semanas, cada uma com uma sequência de issues definidas pelo professor:

Semana 1: coleta dos dados, ambiente, API e estrutura inicial.

Semana 2: EDA, limpeza e primeiras visualizações.

Semana 3: desenvolvimento completo do notebook e do dashboard.

Semana 4: ajustes finais, deploy e relatório.

No Capítulo 3, cada issue contém:

- a) descrição da atividade realizada;
- b) resultados obtidos;
- c) prompt utilizado na etapa.

2.5 Uso da IA Generativa no projeto

A IA foi usada de forma integrada e transparente. As contribuições principais foram:

- a) gerar sugestões de código;
- b) refinar visualizações;
- c) aprimorar explicações conceituais;
- d) estruturar o notebook;
- e) revisar e melhorar a redação acadêmica;
- f) detectar erros rapidamente;
- g) sugerir melhorias estéticas no dashboard.

Esses prompts são apresentados no Capítulo 3, associados a cada issue, garantindo rastreabilidade e transparência metodológica.

2.6 Estrutura dos prompts no relatório

A documentação dos prompts segue esta lógica:

Capítulo 3: prompts selecionados e contextualizados (os realmente usados nas atividades).

Apêndice A: lista integral dos prompts usados durante o projeto.

Essa organização atende simultaneamente:

- a) critérios científicos;
- b) exigências do professor;
- c) transparência do uso da IA.

3 DESENVOLVIMENTO POR SEMANA

Este capítulo descreve, em ordem cronológica, as atividades realizadas ao longo das quatro semanas do projeto Spotify Data Storytelling, correlacionando cada etapa com os prompts efetivamente utilizados na disciplina Análise de Dados com Python, IA e Engenharia de Prompt.

3.1 Semana 1 – Ambientação no Google Colab e Engenharia de Prompt

3.1.1 Atividades desenvolvidas

Na Semana 1, o foco foi a ambientação técnica e a organização do ambiente de trabalho, sem ainda envolver coleta de dados via API. As principais atividades foram:

- a) leitura do material de Engenharia de Prompt disponibilizado pelo professor, com estudo de conceitos como zero-shot, few-shot, chain-of-thought, definição de persona, uso de delimitadores e boas práticas de formulação de prompts.
- b) criação e configuração da conta Google e acesso ao Google Colab com a conta destinada ao projeto.
- c) criação do notebook inicial (spotify.ipynb) e organização no Google Drive, dentro da estrutura de pastas do projeto.
- d) uso de células de Markdown e código, execução de comandos básicos em Python e primeira verificação do ambiente científico.
- e) testes mínimos de EDA de validação, com criação de um pequeno DataFrame em Pandas e geração de um gráfico de barras com Matplotlib, para comprovar a integração entre bibliotecas e backend gráfico.
- f) registro de boas práticas (documentação em Markdown, uso de “Executar tudo”, backup local do notebook etc.).
- g) planejamento preliminar para uso de APIs públicas (incluindo a Web API do Spotify) nas semanas subsequentes.

3.1.2 Prompts utilizados na Semana 1

Conforme o relatório técnico da Semana 1, foram utilizados quatro prompts principais, todos relacionados à ambientação e à documentação técnica:

3.1.2.1 Prompt 1 – Planejamento do relatório (mestre):

“Você é um cientista de dados experiente e redator técnico. Com base nas diretrizes ABNT NBR 10719:2015 e no cronograma da disciplina ‘Análise de Dados com Python, IA e Engenharia de Prompt’ (FAC SENAC DF), gere um RELATÓRIO TÉCNICO completo para a Semana 1, contendo: (1) Introdução; (2) Desenvolvimento com passo a passo detalhado da ambientação no Google Colab (criação de conta, acesso, criação/renomeação de notebook, uso de células de código e Markdown, execução, atalhos, salvar no Drive, instalação de bibliotecas com !pip quando necessário, verificação de versões e troubleshooting); (3) Engenharia de Prompt aplicada com os prompts realmente utilizados; (4) Considerações Finais; (5) Referências. Formatação: Arial 12, 1,5, justificado, margens 3×2; Títulos: nível 1 MAIÚSCULO negrito, nível 2 negrito, nível 3 negrito e itálico. Inclua os prompts literais com objetivo e resultado.”

3.1.2.2 Prompt 2 – Guia de criação e uso do Colab (zero-shot):

“Explique, em passos numerados, como acessar o Colab, criar notebook, salvar no Drive, atalhos, uso de !pip e verificação de versões.”

3.1.2.3 Prompt 3 – Engenharia de Prompt (few-shot):

“Descreva zero-shot, few-shot e chain-of-thought com exemplos aplicáveis a EDA, e liste boas práticas.”

3.1.2.4 Prompt 4 – Troubleshooting (chain-of-thought):

“Liste erros comuns ao instalar/importar e como resolver (reiniciar, checar versão, reinstalar).”

3.2 Semana 2 – coleta, limpeza e transformação de dados via API do Spotify

3.2.1 Atividades desenvolvidas

Na Semana 2, o foco deslocou-se para a coleta de dados reais via Web API do Spotify e a preparação inicial do dataset para análises futuras. As atividades principais foram:

- a) configuração das credenciais no Spotify Developer Dashboard e armazenamento seguro em variáveis secretas no Colab (SPOTIPY_CLIENT_ID e SPOTIPY_CLIENT_SECRET).
- b) autenticação com a API utilizando a biblioteca spotipy e a classe SpotifyClientCredentials, seguindo o fluxo OAuth.
- c) teste de conexão via consulta simples (sp.search(q="genre:pop", type="track")), validando a comunicação RESTful com a API.
- d) coleta de dados musicais utilizando o endpoint /v1/search, com extração de faixas por gênero musical.
- e) identificação de categorias musicais disponíveis no Brasil, seleção de 17 gêneros relevantes e implementação de rotina iterativa e paginada para coleta de até 500 faixas por categoria.
- f) estruturação de um dataset bruto com atributos como: genero, faixa, artista, album, data_lancamento, popularidade, duracao_ms.
- g) exportação do dataset bruto (spotify_raw.csv) e, após tratamento, do dataset consolidado (spotify_semana2_tratado.csv).
- h) processo de limpeza e transformação, incluindo: remoção de duplicatas, conversão de datas, criação de duracao_min, normalização da popularidade (popularidade_norm) e remoção criteriosa de nulos críticos.
- i) validação quantitativa: 17 categorias analisadas, 1.700 faixas coletadas, 890 registros tratados e 7 colunas consolidadas.

3.2.2 Prompts utilizados na Semana 2

A Engenharia de Prompt foi utilizada para apoiar a codificação, o diagnóstico de qualidade e a documentação técnica. Os principais prompts registrados foram:

3.2.2.1 Prompt 1 — Coleta estruturada (few-shot):

“Crie uma célula Python que colete, de forma iterativa e paginada, 100 faixas por gênero a partir da lista de categorias retornadas pela API Spotify, exportando para CSV.”

3.2.2.2 Prompt 2 — Diagnóstico de qualidade (chain-of-thought):

“Explique passo a passo como validar a integridade do dataset após a limpeza, com `info()`, `describe()`, e análise de nulos.”

3.2.2.3 Prompt 3 — Relatório narrativo (zero-shot):

“Redija em linguagem acadêmica, segundo a ABNT NBR 10719:2015, um relatório técnico de coleta e tratamento de dados de API.”

3.3 Semana 3 – EDA, análise interpretativa e protótipo de dashboard

A Semana 3 foi dividida em três issues principais: 3.1 (EDA), 3.2 (Análise Interpretativa) e 3.3 (Protótipo de Dashboard), consolidando o núcleo analítico e visual do projeto.

3.3.1 Issue 3.1 – Análise Exploratória dos Dados (EDA)

3.3.1.1 Atividades desenvolvidas

Com base no arquivo `spotify_semana2_tratado.csv`, foram conduzidas as seguintes atividades:

- a) carregamento e inspeção do dataset (`info()`, `describe()`, `head()`, `tail()`, checagem de nulos e duplicatas, cardinalidade de gêneros e artistas).
- b) verificação de cobertura temporal (anos de lançamento) e distribuição das variáveis numéricas.
- c) construção de visualizações obrigatórias:
 - histograma da popularidade (com e sem faixas de popularidade zero);

- dispersão duração × popularidade, diferenciando faixas com popularidade zero; lançamentos por ano, evidenciando crescimento pós-2010; gráfico de barras por gênero, analisando representatividade e popularidade média.
- d) construção de visualizações avançadas:
 - boxplot de popularidade por gênero;
 - top 20 artistas por popularidade média;
 - artistas com maior número de faixas com popularidade zero;
 - artistas com maior discrepância entre popularidade mínima e máxima.
- e) elaboração de uma célula Markdown consolidando os principais insights da EDA.
- f) implementação de rotina automatizada para exportar todos os gráficos gerados para a pasta /visuals/, com nomes descritivos e organização por subpastas.

3.3.1.2 Prompt utilizado na Issue 3.1

“Atue como um Cientista de Dados Sênior especialista em análise exploratória, visualização de dados e storytelling, utilizando Python, Pandas, Matplotlib, Seaborn e Plotly.

Quero que você realize toda a EDA da Semana 3.1 com base no arquivo `spotify_semana2_tratado.csv`, seguindo rigorosamente as etapas abaixo:

Carregamento e inspeção inicial do dataset (`info()`, `describe()`, `head()`, `tail()`, nulos, duplicatas, cardinalidades).

Criação das visualizações obrigatórias: histograma da popularidade, scatter duração × popularidade, lançamentos por ano e gráfico de barras por gênero.

Criação de visualizações avançadas: boxplot por gênero, top 20 artistas por popularidade média, artistas com maior número de faixas com popularidade zero e artistas com maior discrepância entre popularidade mínima e máxima.

Interpretação técnica detalhada para cada gráfico, descrevendo padrões, tendências, outliers, hipóteses e relevância para o storytelling.

Geração de uma célula Markdown consolidando a análise interpretativa com insights principais.

Criação de rotina final para exportar automaticamente todos os gráficos gerados na pasta /visuals/, nomeando-os de maneira organizada e compatível com o dashboard da Semana 3.3.”

3.3.2 Issue 3.2 – análise Interpretativa e storytelling analítico

3.3.2.1 Atividades desenvolvidas

Nesta etapa, as visualizações e resultados da EDA foram convertidos em análises interpretativas estruturadas, com foco em:

- a) interpretação estatística avançada das variáveis numéricas (popularidade, duracao_min, ano_lancamento, variáveis derivadas).
- b) discussão de tendências, dispersão, outliers, hipóteses culturais e mercadológicas.
- c) análise de possíveis correlações entre popularidade, duração, ano de lançamento e gênero.
- d) classificação de padrões por:
 - artista (consistentes, voláteis, com muitos registros zero);
 - gênero (mainstream vs. nichados);
 - período histórico (pré-2000, 2000–2010, pós-2010);
 - comportamento de engajamento (faixas zero, médio, alto).
- e) interpretação das visualizações produzidas na Issue 3.1, focando em fenômenos (saturação de faixas zero, explosão de lançamentos, padrões por gênero etc.).
- f) produção de uma análise narrativa final, em Markdown (Célula 25), articulando estatística, mercado musical e cultura.

3.3.2.2 Prompt utilizado na Issue 3.2

O prompt utilizado para guiar essa etapa foi:

“Atue como um Cientista de Dados Sênior, especialista em análise interpretativa, storytelling com dados, estatística descritiva e análise cultural/mercadológica aplicada ao mercado musical.

Com base nas visualizações e análises produzidas na Semana 3.1 (EDA), quero que você realize a Issue da Semana 3.2, seguindo rigorosamente as etapas abaixo.

Interpretação Estatística Avançada

Analise profundamente as variáveis numéricas do dataset (popularidade, duracao_min, ano_lancamento e derivadas).

Descreva tendências centrais, dispersões, outliers, implicações culturais e hipóteses relacionadas ao comportamento do usuário e à indústria fonográfica.

Tendências e Correlações

Avalie possíveis relações entre popularidade, duração, ano e gênero.

Interprete se faixas mais recentes são mais populares, se músicas mais curtas engajam mais, e como os gêneros se diferenciam.

Classificação de Padrões

Classifique padrões relevantes por artista, gênero, período ou subcategorias (faixas zero, artistas voláteis, catálogos consistentes).

Produza uma tabela-resumo dos principais padrões.

Interpretação das Visualizações da EDA

Para cada gráfico criado na Issue 3.1, interprete o que ele significa, quais fenômenos revela, e quais hipóteses explicam tais comportamentos.

Análise Narrativa Final

Elabore um texto fluido, técnico e profissional com interpretações, implicações mercadológicas, hipóteses e aplicações práticas para o storytelling e dashboard.

Insights Culturais e Mercadológicos

Explique o que as tendências encontradas revelam sobre padrões culturais de consumo musical.

Entrega Consolidada

Produza:

Um bloco Markdown único para o relatório técnico.

Um resumo executivo com os pontos-chave da análise.”

3.3.3 Issue 3.3 – Protótipo Inicial do Dashboard Interativo

3.3.3.1 Atividades desenvolvidas

A Issue 3.3 teve como meta transformar os resultados da EDA e da análise interpretativa em um protótipo funcional de dashboard. As principais ações foram:

- a) Escolha da ferramenta de prototipação, optando por Streamlit pela integração nativa com Python e Plotly.
- b) Criação do arquivo `spotify_dashboard_app.py`, contendo a estrutura inicial do dashboard.
- c) Implementação de abas temáticas:
 - Visão Geral – histograma de popularidade, dispersão duração × popularidade, KPIs (total filtrado, popularidade média, % de faixas zero, duração média);
 - Gêneros – boxplot de popularidade por gênero, estatísticas descritivas;
 - Artistas – top artistas por popularidade média, artistas com maior discrepância, artistas com mais faixas de popularidade zero;
 - Linha do tempo – lançamentos por ano e leitura das tendências temporais.
- d) Implementação de filtros interativos (multiselect de gêneros, controle de período de anos, limite mínimo de popularidade).
- e) Integração de storytelling inicial dentro da interface, com textos explicativos sobre os gráficos.
- f) Documentação da criação do protótipo e salvamento do arquivo `.py` no ambiente, para posterior versionamento no GitHub.

3.3.3.2 Prompt utilizado na Issue 3.3

O prompt registrado para esta etapa foi:

“Atue como um Cientista de Dados Sênior, especialista em Storytelling Visual, Design de Dashboards e prototipação rápida usando ferramentas como Lovable, Streamlit ou Bolt.

Agora quero que você desenvolva o PROTÓTIPO INICIAL DO DASHBOARD da Semana 3, integrando as análises e visualizações que construímos nas Issues 3.1 e 3.2.

Siga rigorosamente as etapas abaixo.

Escolha da ferramenta de prototipação

Seleção das visualizações essenciais

Definição do storytelling visual

Inserção das visualizações no protótipo

Bloco de storytelling automático dentro do dashboard

Garantir design limpo e intuitivo

Gerar o protótipo final exportável

Redigir o texto de documentação para o relatório técnico

Cumprir TODAS AS ETAPAS acima.”

3.4 Semana 4 – insights automáticos com IA e dashboard final

A Semana 4 consolidou a dimensão IA-driven do projeto e a estrutura final do dashboard, dividindo-se em Issue 4.1 (integração de insights automáticos) e Issue 4.2 (consolidação e preparo para deploy).

3.4.1 Issue 4.1 – Integração de Insights Automáticos com IA

3.4.1.1 Atividades desenvolvidas

Nesta issue, o objetivo foi integrar Inteligência Artificial generativa ao projeto, criando um módulo de insights automáticos e textos narrativos para o dashboard. As atividades incluíram:

- a) desenvolvimento de um prompt mestre contendo: descrição do dataset tratado, resultados da EDA, análise interpretativa, protótipo de dashboard e requisitos de geração textual.
- b) geração de um pacote de 30+ insights automáticos, agrupados por temas (tendências gerais, gêneros, artistas, popularidade, duração, linha do tempo, faixas zero, volatilidade/consistência, curadoria de catálogo).

- c) produção de blocos textuais prontos para uso no dashboard:
 - texto introdutório da página principal;
 - descrições das abas;
 - tooltips;
 - conclusões narrativas;
 - mensagens dinâmicas baseadas em filtros.
- d) elaboração de sugestões IA-driven para aprimorar o dashboard (novas visualizações, indicadores dinâmicos, modo storytelling guiado etc.).
- e) modelagem conceitual de uma API fictícia para integração IA ↔ dashboard, com endpoints, payloads e exemplos de request/response em JSON.

3.4.1.2 Prompt utilizado na Issue 4.1

O prompt mestre utilizado foi:

“Atue como um Cientista de Dados Sênior, especialista em engenharia de prompt, storytelling com dados, análise textual automática, IA generativa aplicada e mercado musical.

Você receberá:

O dataset tratado do projeto Spotify Data Storytelling (popularidade, duração, ano, gênero e artista);

Os resultados completos da análise EDA (Semana 3.1);

A análise interpretativa e narrativa (Semana 3.2);

O protótipo do dashboard Streamlit (Semana 3.3);

Os gráficos e padrões encontrados até agora.

Seu objetivo é cumprir integralmente a Issue 4.1 – Integração de insights automáticos com IA, seguindo rigorosamente as etapas abaixo.

Gerar insights automáticos (via IA) com alta precisão

[...]

Gere no mínimo 20 a 30 insights, agrupados por tema:

✓ Tendências gerais

✓ Gêneros musicais

✓ Artistas

✓ Popularidade

- ✓ Duração
- ✓ Linha do tempo
- ✓ Faixas zero (cauda longa)
- ✓ Volatilidade e consistência
- ✓ Curadoria de catálogo
- Criar textos gerados automaticamente para o dashboard
- [...]
- Criar sugestões de componentes interativos
- [...]
- Simular integração API (não precisa executar código)
- [...]
- Criar texto final da Issue 4.1 (para o relatório)
- [...]

ENTREGAS

Produza:

Insight Pack Automático – 30+ insights

Blocos textuais para o dashboard

Sugestões IA-driven

Modelo de integração API

Texto final da Issue 4.1 para o relatório (markdown completo)

Resumo executivo com até 12 linhas

Use linguagem clara, técnica, analítica e narrativa.

Não omita detalhes.

A análise deve ser profunda e digna de um relatório profissional.”

3.4.2 Issue 4.2 – dashboard final, integração IA ↔ dashboard e deploy

3.4.2.1 Atividades desenvolvidas

Na Issue 4.2, o objetivo foi consolidar todas as etapas anteriores e preparar o dashboard final em Streamlit para deploy. As principais atividades foram:

- a) integração do storytelling consolidado (Célula 30), reunindo padrões de popularidade, consistência/volatilidade, comportamento dos gêneros,

análise temporal, duração × engajamento, cauda longa, leitura mercadológica e implicações culturais.

- b) geração de textos IA-driven (Célula 31) para cada aba do dashboard, incluindo descrições dinâmicas, tooltips e mensagens automáticas sensíveis aos filtros.
- c) listagem de sugestões avançadas para componentes interativos e módulos futuros (Célula 32).
- d) detalhamento da arquitetura de uma API fictícia para integração IA ↔ dashboard, com endpoints como /insights, /storytelling e /explain, exemplificando payloads JSON (Célula 33).
- e) preparação para o deploy no Streamlit Cloud, incluindo criação/ajuste de requirements.txt, estrutura /data e documentação de deploy (README_DEPLOY.md) (Células 34 e 35).
- f) verificação final de funcionamento e organização do projeto, garantindo que o dashboard final estivesse pronto para publicação e apresentação.

3.4.2.2 Prompt utilizado na Issue 4.2

O relatório técnico da Semana 4.2 registra o seguinte prompt (que, embora mencione “Issue 4.1” no texto interno, foi utilizado para executar a Issue 4.2):

“Atue como um Cientista de Dados Sênior, especialista em engenharia de prompt, storytelling com dados, análise textual automática, IA generativa aplicada e mercado musical.

Você receberá:

O dataset tratado do projeto Spotify Data Storytelling (popularidade, duração, ano, gênero, artista etc.)

Os resultados completos da análise EDA (Semana 3.1)

A análise interpretativa e narrativa (Semana 3.2)

O protótipo do dashboard Streamlit (Semana 3.3)

Os gráficos e padrões encontrados até agora

Seu objetivo é cumprir integralmente a Issue 4.1 – Integração de insights automáticos com IA.”

(Nos desdobramentos desse prompt foram produzidos os textos finais de storytelling, os blocos IA-driven, a modelagem de API fictícia e a preparação para deploy, que compõem a entrega da Issue 4.2.)

4 DASHBOARD INTERATIVO

O dashboard desenvolvido no projeto Spotify Data Storytelling representa a etapa final do pipeline analítico, integrando o dataset tratado, as visualizações produzidas ao longo da EDA (Semana 3.1), as interpretações analíticas (Semana 3.2) e os insights automáticos gerados por IA (Semana 4.1). Construído em Streamlit, o dashboard oferece uma interface moderna, responsiva e interativa, permitindo que o usuário explore padrões musicais de forma dinâmica e baseada em evidências.

O objetivo central do dashboard é traduzir análises técnicas em uma experiência visual acessível, organizada em abas temáticas e enriquecida com módulos narrativos gerados automaticamente via IA generativa.

4.1 Arquitetura do dashboard

A estrutura lógica e visual do dashboard foi planejada para garantir organização, performance e usabilidade. Sua arquitetura divide-se em três camadas:

4.1.1 Camada de Dados

- a) Dataset tratado: `spotify_semana2_tratado.csv`
- b) Variáveis principais:
 - faixa, artista, gênero, popularidade, `duracao_min`, `ano_lancamento`
- c) Métricas derivadas:
 - `popularidade_norm`, duração categorizada, classificação por faixas zero

4.1.2 Camada Analítica

- a) Visualizações com Plotly (interativas)
- b) KPIs dinâmicos
- c) Storytelling automático (IA)
- d) Interpretação contextual embutida na interface

4.1.3 Camada Visual/Interativa

- a) Streamlit

- b) Abas temáticas
- c) Filtros laterais
- d) KPIs com destaque
- e) Gráficos responsivos

4.2 Estrutura geral da interface

O dashboard foi organizado em quatro abas principais, cada uma mapeando um bloco analítico do projeto:

4.2.1 Aba “Visão Geral”

A primeira aba funciona como um “painel executivo”, oferecendo uma leitura instantânea do comportamento do dataset. Inclui:

KPIs principais:

- a) total de faixas
- b) popularidade média
- c) proporção de faixas com popularidade zero
- d) duração média (minutos)
- e) histogramas de popularidade (com e sem faixas zero)
- f) gráfico de dispersão (popularidade × duração)
- g) distribuição temporal por ano de lançamento

Essa aba foi desenhada para apresentar rapidamente o “retrato geral” do catálogo analisado, servindo como porta de entrada para as demais.

4.2.2 Aba “Gêneros Musicais”

Dedicada à análise comparativa entre gêneros, contém:

- a) boxplot de popularidade por gênero
- b) ranking de gêneros por popularidade média
- c) densidade de distribuição por gênero
- d) tabelas estatísticas derivadas
- e) insights automáticos gerados por IA sobre comportamento de gêneros:

Ex.: “Gêneros X e Y apresentam cauda longa consistente, indicando maior volume de faixas com baixa popularidade.”

Essa aba permite compreender diferenças estruturais entre os gêneros mais e menos performáticos do dataset.

4.2.3 Aba “Artistas”

A aba de artistas aprofunda o comportamento individual por catálogo:

- a) top 20 artistas por popularidade média
- b) artistas com maior discrepância popularidade mínima × máxima
- c) artistas com mais faixas de popularidade zero
- d) gráficos de universalização (escala logarítmica)
- e) texto interpretativo automático, incluindo:

“Artistas com grande discrepância entre faixas indicam volatilidade no catálogo, sinalizando presença de hits isolados.”

Essa aba ajuda a identificar padrões de consistência, volatilidade e engajamento.

4.2.4 Aba “Linha do Tempo”

A análise temporal centraliza as interpretações sobre tendências históricas:

- a) Contagem de lançamentos por ano
- b) Tendência pós-2010
- c) Períodos de maior atividade
- d) Correlação entre ano e popularidade
- e) Storytelling temporal:

“A explosão de lançamentos após 2010 coincide com a expansão das plataformas digitais e do streaming como modelo dominante.”

Essa aba revela como a evolução do mercado musical influencia padrões de consumo.

4.3 Filtros Interativos

Todos os gráficos do dashboard são influenciados pelos filtros à esquerda da tela:

- a) seletor de gêneros (multiselect)
- b) período de anos
- c) intervalo mínimo de popularidade
- d) duração mínima e máxima

Esses filtros tornam a análise flexível e permitem que o usuário crie narrativas próprias sobre o dataset.

4.4 KPIs e Indicadores Dinâmicos

O dashboard exibe KPIs calculados em tempo real conforme os filtros aplicados:

- a) popularidade média
- b) % de faixas zero
- c) duração média das músicas
- d) quantidade total filtrada
- e) número de artistas únicos
- f) número de gêneros ativos

Esses indicadores dão suporte à tomada de decisão e facilitam leituras rápidas do dataset filtrado.

4.5 Integração com IA Generativa

A integração com IA (realizada na Semana 4.1) insere uma camada automatizada de interpretação e storytelling dentro do dashboard.

Foram implementados:

4.5.1 Insights Automáticos

Mais de 30 insights estruturados por tema:

- a) tendências gerais
- b) gêneros musicais

- c) artistas
 - d) popularidade
 - e) duração
 - f) linha do tempo
 - g) cauda longa (faixas zero)
 - h) consistência vs. volatilidade
- curadoria de catálogo

4.5.2 Storytelling Automático

Mensagens geradas pela IA aparecem:

- a) nos textos introdutórios da aba “Visão Geral”;
- b) nas descrições das abas;
- c) como tooltips explicativos;
- d) como interpretações automáticas sensíveis aos filtros.

Exemplo:

“Faixas com duração entre 2,5 e 3,5 minutos apresentam o melhor equilíbrio entre consistência e alta popularidade no catálogo filtrado.”

4.5.3 Sugestões IA-driven

A IA sugeriu melhorias futuras, como:

- a) modo “explicação automática” (IA descreve o gráfico selecionado)
- b) análise preditiva usando modelos leves
- c) integração com API externa para insights em tempo real

4.6 Arquitetura de API (Modelo Conceitual)

Para fins didáticos, foi modelada uma API conceitual que permitiria comunicação IA ↔ Dashboard.

Endpoints exemplificados:

POST /insights → retorna insights calculados automaticamente

POST /storytelling → gera textos interpretativos sob demanda

POST /explain → IA explica o gráfico exibido

Exemplo simplificado de request:

```
{  
  "genero": ["pop", "rock"],  
  "ano_min": 2015,  
  "popularidade_min": 50  
}
```

Exemplo de response:

```
{  
  "insight": "Faixas pop pós-2015 apresentam crescimento consistente de  
popularidade média."  
}
```

Essa modelagem reforça o componente pedagógico da disciplina (IA + Python + APIs).

4.7 Preparação para Deploy

A etapa final incluiu:

- a) organização da estrutura /app, /data, /visuals
- b) limpeza do código
- c) criação de requirements.txt
- d) criação de README_DEPLOY.md com instruções
- e) testes para deploy no Streamlit Cloud e simulações de deploy via Vercel

A versão final foi validada localmente e deixou pronta a estrutura para publicação pública.

4.8 Considerações sobre design e usabilidade

O dashboard buscou seguir princípios de UX aplicados a Visual Analytics:

- a) design limpo, cores consistentes
- b) alinhamento visual
- c) transições suaves nos gráficos
- d) texto objetivo ao lado das visualizações
- e) menus laterais minimalistas

f) responsividade total para desktop

O resultado é um produto analítico que combina:

- a) estética,
- b) interatividade,
- c) clareza,
- d) storytelling,
- e) e IA generativa.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os principais resultados obtidos ao longo do projeto Spotify Data Storytelling, articulando as descobertas quantitativas da Análise Exploratória dos Dados (EDA), as interpretações qualitativas derivadas da análise narrativa e os insights automáticos gerados pela Inteligência Artificial. A discussão é estruturada a partir dos eixos analíticos do dashboard: popularidade, gêneros musicais, artistas, duração das faixas e evolução temporal.

Os resultados, apresentados a seguir, demonstram como a combinação de dados reais, análise estatística, visualização interativa e IA generativa permitiu construir um painel interpretativo robusto, capaz de revelar padrões consistentes sobre a dinâmica musical contemporânea.

5.1 Padrões gerais do dataset

A análise descritiva do dataset tratado revelou um conjunto de características estruturais relevantes:

- a) número total de faixas analisadas: 890
- b) gêneros contemplados: 17 categorias musicais
- c) período dos lançamentos: de 1950 a 2024
- d) popularidade média aproximada: entre 35 e 40 pontos (escala 0 a 100)
- e) proporção de faixas com popularidade zero: significativa, compondo a chamada cauda longa

Esses resultados já sugerem relações importantes entre distribuição de engajamento, diversidade musical e dinâmica do mercado de streaming.

5.2 Popularidade: distribuição, cauda longa e consistência

A variável popularidade mostrou-se altamente assimétrica:

5.2.1 Distribuição geral

Os histogramas revelaram que:

- a) a maior parte das faixas concentra-se entre 0 e 40 pontos,
- b) poucas faixas ultrapassam 70 pontos,

c) o grupo de faixas com popularidade zero é numeroso.

Esses achados confirmam um fenômeno amplamente documentado no mercado musical digital: a cauda longa, onde uma pequena parcela de faixas concentra a maior parte do engajamento.

5.2.2 Faixas “zero popularidade”

As faixas com popularidade zero se destacaram por dois motivos:

- a) volume expressivo → indicativo de saturação de catálogo.
- b) padrões específicos por gênero e artista → alguns gêneros possuem mais registros zero que outros.

Essas faixas representam baixa circulação/engajamento, podendo refletir:

- a) lançamentos recentes,
- b) produções de nicho,
- c) baixa divulgação,
- d) saturação de mercado.

5.2.3 Consistência da popularidade

A análise artista a artista mostrou:

- a) catálogos consistentes → artistas com pouca variação entre popularidade mínima e máxima;
- b) catálogos voláteis → artistas com grande discrepância entre seus maiores e menores desempenhos.

Essa distinção é útil para entender carreiras, estratégias de lançamento e presença cultural.

5.3 Gêneros musicais: desempenho, variabilidade e nichos

A aba dedicada aos gêneros musicais revelou diferenças notáveis entre categorias:

5.3.1 Popularidade média por gênero

Alguns gêneros apresentam desempenho sistematicamente acima da média geral, enquanto outros se destacam por volumes menores, porém com alto potencial interpretativo.

Gêneros com melhor média tendem a ser:

- a) mainstream,
- b) amplamente difundidos,
- c) associados à cultura pop global.

Já gêneros de nicho, embora com médias inferiores, demonstram grande variabilidade interna.

5.3.2 Boxplot por gênero

O boxplot permitiu visualizar:

- a) dispersões distintas,
- b) medianas diferenciadas,
- c) presença de outliers interessantes.
- d) Interpretativamente, isso mostra que:
- e) gêneros como Pop e Hip-Hop apresentam maior regularidade,
- f) gêneros experimentais (ou híbridos) possuem distribuição mais espalhada,
- g) alguns gêneros têm forte concentração de faixas zero.

5.3.3 Insights culturais

A IA trouxe interpretações úteis:

- a) gêneros mais homogêneos sugerem mercado mais estabilizado;
- b) gêneros com grande faixa de outliers indicam experimentos estéticos, tendências emergentes ou combinações híbridas.

5.4 Artistas: volume, volatilidade e padrões de catálogo

A análise dos artistas foi particularmente reveladora:

5.4.1 Top 20 artistas por popularidade média

A listagem dos principais artistas mostrou um domínio de:

- a) nomes altamente reconhecidos,
- b) artistas com forte presença digital,
- c) perfis de grande engajamento global.

5.4.2 Volatilidade de catálogo

A comparação entre popularidade mínima e máxima permitiu identificar:

- a) artistas com catálogo consistente → poucos picos;
- b) artistas com catálogo volátil → grandes disparidades entre hits e faixas pouco consumidas.

A volatilidade pode ser interpretada como:

- a) presença de “grandes sucessos isolados”,
- b) estratégias de lançamento mais experimentais,
- c) maior exposição ao risco de performance.

5.4.3 Artistas com mais faixas zero

Este grupo representa:

- a) baixa circulação,
- b) lançamentos recentes,
- c) pouca presença em playlists grandes,
- d) faixas que não atingiram público amplo.

Essa métrica complementa a leitura de mercado, evidenciando como algoritmos e estratégias de distribuição modulam o engajamento.

5.5 Análise temporal: tendências históricas

A dimensão histórica destacou tendências claras na evolução da indústria:

5.5.1 Crescimento pós-2010

Os dados mostram uma explosão no número de lançamentos a partir de 2010, coincidindo com:

- a) consolidação do streaming,
- b) queda da mídia física,
- c) democratização da produção musical digital.

5.5.2 Relação ano × popularidade

Os resultados indicam que:

- a) faixas mais recentes não são necessariamente mais populares,
- b) mas possuem maior probabilidade de engajamento inicial,
- c) músicas antigas permanecem relevantes quando associadas a artistas já consolidados.

5.5.3 Hipóteses interpretativas

A IA interpretou o comportamento temporal como reflexo de:

- a) ciclos culturais,
- b) tendências transitórias,
- c) impacto de plataformas,
- d) crescimento exponencial de lançamentos independentes.

5.6 Duração das faixas: tendências e comportamento

A análise de dispersão (popularidade × duração) revelou padrões interessantes:

- a) faixas entre 2,5 e 3,5 minutos concentram maior equilíbrio entre volume e engajamento;
- b) músicas muito curtas ou muito longas tendem a apresentar menor desempenho;
- c) o padrão é consistente com tendências contemporâneas do streaming (faixas mais curtas, replay, viralização).

Esse comportamento reforça estudos recentes sobre otimização de faixas para consumo rápido.

5.7 Integração IA + storytelling: contribuições relevantes

A integração com IA generativa trouxe elementos inovadores ao projeto:

5.7.1 Insights automáticos

Os mais de 30 insights elaborados pela IA permitiram:

- a) detectar padrões ocultos,
- b) complementar análises estatísticas,
- c) enriquecer o conteúdo interpretativo do dashboard.

5.7.2 Textos explicativos integrados ao dashboard

A IA contribuiu com:

- a) descrições de abas,
- b) tooltips,
- c) interpretações automáticas baseadas nos filtros.

Isso elevou o nível de acessibilidade do dashboard para usuários não técnicos.

5.7.3 Sugestões avançadas

Entre as sugestões:

- a) modo “explique o gráfico”,
- b) análise IA sob demanda,
- c) métricas dinâmicas,
- d) expansão do storytelling.

5.8 Síntese dos principais achados

A partir da análise completa, destacam-se sete conclusões centrais:

- a) o dataset apresenta forte assimetria, com grande concentração de faixas de baixa popularidade (cauda longa);

- b) gêneros mainstream tendem a apresentar maior estabilidade e médias mais altas;
- c) artistas variam amplamente em consistência, revelando perfis de catálogo distintos;
- d) a explosão de lançamentos pós-2010 é reflexo direto da ascensão do streaming;
- e) faixas com maior probabilidade de engajamento concentram-se na faixa de 2,5 a 3,5 minutos;
- f) a IA generativa complementou o processo analítico, gerando insights qualitativos e ampliando a compreensão dos dados;
- g) o dashboard integra todos esses elementos, oferecendo um panorama visual, narrativo e quantitativo coerente.

CONCLUSÃO

O projeto Spotify Data Storytelling permitiu integrar, em um fluxo único, três pilares fundamentais da Ciência de Dados contemporânea: análise quantitativa, visualização interativa e Inteligência Artificial generativa aplicada ao storytelling. A partir dos dados coletados pela API pública do Spotify, foi construído um pipeline completo que envolveu coleta, limpeza, transformação, análise exploratória, geração de insights, construção de dashboard e documentação técnica estruturada.

Do ponto de vista analítico, o estudo revelou padrões importantes do catálogo musical coletado. A distribuição assimétrica da popularidade, marcada por grande concentração de faixas de baixa repercussão, reforça fenômenos conhecidos do mercado digital, como a cauda longa. Gêneros musicais se mostraram heterogêneos em seus desempenhos, destacando tanto a força de categorias mainstream quanto a riqueza interpretativa de gêneros de nicho. A análise artista a artista trouxe diagnósticos valiosos sobre consistência de catálogo, volatilidade, predominância de hits isolados e diferenças estratégicas de presença digital. A dimensão temporal evidenciou a influência histórica do streaming, com crescimento expressivo de lançamentos após 2010.

A integração com IA generativa representou um diferencial metodológico. A IA foi capaz de ampliar a profundidade interpretativa, automatizar insights e contribuir com textos explicativos, enriquecendo o dashboard com narrativas dinâmicas e acessíveis. Essa abordagem reforça a relevância de técnicas emergentes que combinam análise tradicional com ferramentas de inteligência artificial, aproximando o aluno de práticas reais adotadas em empresas de tecnologia, marketing, recomendação musical e análise de comportamento do usuário.

O dashboard final, desenvolvido em Streamlit, consolida o produto do projeto ao oferecer uma interface moderna, intuitiva e responsiva. Suas abas temáticas, Visão Geral, Gêneros, Artistas e Linha do Tempo, permitem ao usuário explorar padrões, filtrar dados e construir narrativas próprias. Os textos auxiliares gerados pela IA e a modularidade do design tornam o dashboard acessível tanto a analistas quanto a usuários com menor familiaridade com ferramentas de dados.

Do ponto de vista pedagógico, o projeto proporcionou uma experiência completa de end-to-end data storytelling, contemplando práticas fundamentais como: uso de APIs, construção de notebooks científicos, engenharia de dados, visualização

interativa, integração com IA e deploy para publicação. Essa integração fortalece competências essenciais do profissional de Ciência de Dados, ao mesmo tempo em que estimula autonomia, pensamento crítico e capacidade de comunicação analítica.

Como perspectivas futuras, destacam-se possibilidades de evolução do trabalho, tais como:

- a) incorporação de modelos de machine learning para previsão de popularidade, clustering de gêneros ou detecção de padrões ocultos;
- b) construção de uma API real para geração de insights sob demanda;
- c) integração com bases de dados externas (YouTube, TikTok, Last.fm), permitindo análises comparativas;
- d) expansão do dashboard para suportar análises personalizadas por usuário (perfil de escuta, playlists, recomendações);
- e) aprimoramento do storytelling automático com geração contextualizada em tempo real.

Em síntese, o projeto atingiu seus objetivos e demonstrou que a combinação entre dados musicais, técnicas analíticas e IA generativa é capaz de produzir uma solução completa, tecnicamente robusta e alinhada às demandas contemporâneas da área de dados. O trabalho evidencia que a prática integrada e interdisciplinar, envolvendo estatística, programação, visualização e IA, constitui um caminho eficaz para desenvolver soluções analíticas modernas e relevantes.

REFERÊNCIAS

- ABNT – Associação Brasileira de Normas Técnicas.** NBR 10719:2015 — *Relatório técnico e científico – Apresentação*. Rio de Janeiro: ABNT, 2015.
- ABNT – Associação Brasileira de Normas Técnicas.** NBR 6023:2018 — *Informação e documentação – Referências – Elaboração*. Rio de Janeiro: ABNT, 2018.
- ABNT – Associação Brasileira de Normas Técnicas.** NBR 6028:2021 — *Resumo — Apresentação*. Rio de Janeiro: ABNT, 2021.
- PANDAS DEVELOPMENT TEAM.** *Pandas Documentation*. 2024. Disponível em: <https://pandas.pydata.org/>. Acesso em: 25 nov. 2025.
- PLOTLY TECHNOLOGIES INC.** *Plotly Documentation*. 2024. Disponível em: <https://plotly.com/python/>. Acesso em: 25 nov. 2025.
- PYTHON SOFTWARE FOUNDATION.** *Python 3.11 Documentation*. 2024. Disponível em: <https://docs.python.org/3.11/>. Acesso em: 25 nov. 2025.
- SPOTIFY TECHNOLOGY S.A.** *Spotify Web API — Official Documentation*. 2024. Disponível em: <https://developer.spotify.com/documentation/web-api/>. Acesso em: 12 nov. 2025.
- SPOTIFY TECHNOLOGY S.A.** *Relatórios institucionais e dados de mercado*. 2024. Disponível em: <https://newsroom.spotify.com/>. Acesso em: 10 nov. 2025.
- STREAMLIT INC.** *Streamlit Documentation*. 2024. Disponível em: <https://docs.streamlit.io/>. Acesso em: 22 nov. 2025.
- VANDERPLAS, Jake.** *Python Data Science Handbook*. O'Reilly Media, 2016.
- WASKOM, Michael.** *Seaborn: Statistical Data Visualization*. Journal of Open Source Software, v. 6, n. 60, p. 3021, 2021.

APÊNDICE A – Prompts utilizados

Prompt 1 — Planejamento e redação do relatório técnico da Semana 1

“Você é um cientista de dados experiente e redator técnico. Com base nas diretrizes ABNT NBR 10719:2015 e no cronograma da disciplina ‘Análise de Dados com Python, IA e Engenharia de Prompt’ (FAC SENAC DF), gere um RELATÓRIO TÉCNICO completo para a Semana 1, contendo: (1) Introdução; (2) Desenvolvimento com passo a passo detalhado da ambientação no Google Colab (criação de conta, acesso, criação/renomeação de notebook, uso de células de código e Markdown, execução, atalhos, salvar no Drive, instalação de bibliotecas com !pip quando necessário, verificação de versões e troubleshooting); (3) Engenharia de Prompt aplicada com os prompts realmente utilizados; (4) Considerações Finais; (5) Referências. Formatação: Arial 12, 1,5, justificado, margens 3×2; Títulos: nível 1 MAIÚSCULO negrito, nível 2 negrito, nível 3 negrito e itálico. Inclua os prompts literais com objetivo e resultado.”

Prompt 2 — Guia de acesso e uso do Google Colab

“Explique, em passos numerados, como acessar o Colab, criar notebook, salvar no Drive, atalhos, uso de !pip e verificação de versões.”

Prompt 3 — Engenharia de Prompt: conceitos fundamentais

“Descreva zero-shot, few-shot e chain-of-thought com exemplos aplicáveis a EDA, e liste boas práticas.”

Prompt 4 — Troubleshooting no Google Colab

“Liste erros comuns ao instalar/importar e como resolver (reiniciar, checar versão, reinstalar).”

Prompt 5 — Coleta estruturada de faixas via API Spotify (Semana 2)

“Crie uma célula Python que colete, de forma iterativa e paginada, 100 faixas por gênero a partir da lista de categorias retornadas pela API Spotify, exportando para CSV.”

Prompt 6 — Diagnóstico de qualidade do dataset após a limpeza

“Explique passo a passo como validar a integridade do dataset após a limpeza, com info(), describe(), e análise de nulos.”

Prompt 7 — Relatório narrativo da coleta e tratamento de dados

“Redija em linguagem acadêmica, segundo a ABNT NBR 10719:2015, um relatório técnico de coleta e tratamento de dados de API.”

Prompt 8 — EDA completa (Semana 3.1)

“Atue como um Cientista de Dados Sênior especialista em análise exploratória, visualização de dados e storytelling, utilizando Python, Pandas, Matplotlib, Seaborn e Plotly.

Quero que você realize toda a EDA da Semana 3.1 com base no arquivo `spotify_semana2_tratado.csv`, seguindo rigorosamente as etapas abaixo:

Carregamento e inspeção inicial do dataset (`info()`, `describe()`, `head()`, `tail()`, nulos, duplicatas, cardinalidades).

Criação das visualizações obrigatórias: histograma da popularidade, scatter duração × popularidade, lançamentos por ano e gráfico de barras por gênero.

Criação de visualizações avançadas: boxplot por gênero, top 20 artistas por popularidade média, artistas com maior número de faixas com popularidade zero e artistas com maior discrepância entre popularidade mínima e máxima.

Interpretação técnica detalhada para cada gráfico.

Geração de célula Markdown consolidando insights principais.

Rotina de exportação automática dos gráficos para a pasta `/visuals/`.”

Prompt 9 — Análise interpretativa e storytelling analítico (Semana 3.2)

“Atue como um Cientista de Dados Sênior, especialista em análise interpretativa, storytelling com dados, estatística descritiva e análise cultural/mercadológica aplicada ao mercado musical.

Com base nas visualizações e análises produzidas na Semana 3.1, realize a Issue 3.2, seguindo rigorosamente as etapas abaixo:

Interpretação estatística avançada das variáveis.

Avaliação de correlações possíveis entre popularidade, duração, ano e gênero.

Classificação de padrões por artista, gênero e período.

Interpretação de cada gráfico da EDA.

Produção de narrativa técnica final.

Geração de resumo executivo.”

Prompt 10 — Protótipo inicial do dashboard (Semana 3.3)

“Atue como um Cientista de Dados Sênior, especialista em Storytelling Visual, Design de Dashboards e prototipação rápida usando ferramentas como Lovable, Streamlit ou Bolt.

Quero que você desenvolva o PROTÓTIPO INICIAL DO DASHBOARD da Semana 3, integrando as análises produzidas nas Issues 3.1 e 3.2.

Inclua escolha da ferramenta, seleção de visualizações, storytelling visual, inserção dos gráficos, bloco de storytelling automático, design limpo e documentação completa.”

Prompt 11 — Geração de insights automáticos com IA (Semana 4.1)

“Atue como um Cientista de Dados Sênior, especialista em engenharia de prompt, storytelling com dados, análise textual automática, IA generativa aplicada e mercado musical.

Você receberá o dataset tratado, a EDA, a análise narrativa e o protótipo do dashboard.

Seu objetivo é cumprir integralmente a Issue 4.1 – Integração de insights automáticos com IA.

Gere no mínimo 20 a 30 insights, agrupados por tema (tendências gerais, gêneros, artistas, popularidade, duração, linha do tempo, faixas zero, volatilidade etc.).

Crie textos explicativos para o dashboard, sugestões IA-driven e o texto final da Issue 4.1.

Produza também um resumo executivo e um modelo de integração API fictícia.”

Prompt 12 — Consolidação final do dashboard e preparação para deploy (Semana 4.2)

“Atue como um Cientista de Dados Sênior, especialista em engenharia de prompt, storytelling com dados, análise textual automática, IA generativa aplicada e mercado musical.

Você receberá o dataset tratado, a EDA, a análise narrativa e o protótipo.

Seu objetivo é consolidar o dashboard final, criar storytelling avançado, sugerir melhorias, estruturar a arquitetura de uma API fictícia, gerar o texto final da Issue 4.2 e preparar os arquivos para deploy (requirements, organização de pastas, README de deploy etc.).”

Prompt 13 — Introdução do relatório final

“Escreva uma introdução acadêmica completa para um relatório final do projeto Spotify Data Storytelling, incluindo contextualização histórica do streaming musical, apresentação do Spotify como fonte de dados, definição do problema, objetivos, justificativa e estrutura do relatório.”

Prompt 14 — Notebook completo e ajustado

“Traga o notebook completo, revisado e corrigido, com todas as células funcionando, reorganização interna, correção de erros, melhorias visuais e a melhor versão possível do notebook Spotify.”

Prompt 15 — app.py completo em Streamlit

“Crie um app.py completo e moderno em Streamlit para um dashboard do Spotify. Inclua sidebar, múltiplas abas (Visão Geral, Artistas, Gêneros, Temporalidade), gráficos Plotly interativos, KPIs e análise automatizada. Quero o código completo, otimizado e elegante.”

Prompt 16 — Preparação para deploy em Vercel/Streamlit Cloud

“Prepare o app Streamlit para deploy. Ajuste o requirements.txt, reorganize a estrutura, remova arquivos incompatíveis com Vercel e traga instruções e correções no app.py para funcionar no deploy.”

Prompt 17 — Revisão completa do relatório final

“Revise o relatório completo do projeto Spotify Data Storytelling e traga a versão final estruturada em capítulos. Ajuste a escrita para tom acadêmico, corrija coerência e integre a explicação do método, do notebook e do dashboard.”